BỘ CÔNG THƯƠNG

TRƯỜNG ĐẠI HỌC KINH TẾ KỸ THUẬT CÔNG NGHIỆP

KHOA: KHOA HỌC ỨNG DỤNG

TIỂU LUẬN

NGHIÊN CỨU ỨNG DỤNG HỌC SÂU TRONG BÀI TOÁN PHÂN ĐOẠN ẢNH (IMAGE SEGMENTATION)

Học phần:	Học sâu
Lớp:	DHKL16A1HN
Nhóm:	2
Thành viên:	Lê Thị Lan Nguyễn Khang
GVHD:	ThS.Trần Quốc Hưng

HÀ NỘI – 2025

MỤC LỤC

DANH MỤC CÁC BẢNG BIỂU i
DANH MỤC CÁC HÌNH VẼ ii
DANH MỤC CÁC KÍ HIỆU, CHỮ VIẾT TẮT iii
LỜI CẢM ƠN 1
MỞ ĐẦU 2
CHƯƠNG 1: CƠ SỞ LÝ THUYẾT 3
1.1. **GIỚI THIỆU BÀI TOÁN PHÂN ĐOẠN ẢNH** 3
1.1.1. Khái niệm 3
1.1.2. Phân loại 3
1.1.3. Ứng dụng thực tiễn 4
1.1.4. Phương pháp phân đoạn ảnh 5
1.2. CÁC MÔ HÌNH HỌC SÂU SỬ DỤNG 7
1.2.1. Mô hình U-Net 7
1.2.2. Mô hình FCN – ResNet 12
1.2.3. Các chỉ số đánh giá mô hình 16
1.3. KẾT LUẬN CHƯƠNG 19
CHƯƠNG 2: THỰC NGHIỆM 20
2.1. CHUẨN BỊ DỮ LIỆU 20
2.1.1. Giới thiệu về bộ dữ liệu 20
2.1.2. Khám phá dữ liệu 20
2.1.3. Xử lý dữ liệu 23
2.2. XÂY DỰNG MÔ HÌNH 23
2.2.1. Mô hình U-Net 23
2.2.2. Mô hình FCN – Resnet34 27
2.3. ĐÁNH GIÁ MÔ HÌNH 31
2.3.1. Mô hình U-Net 31
2.3.2. Mô hình FCN – ResNet 33
2.3.3. So sánh hai mô hình 35
2.4. KẾT LUẬN CHƯƠNG 36
CHƯƠNG 3: KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN 37
3.1. KẾT LUẬN 37
3.1.1. Về dữ liệu và đặc điểm bài toán 37
3.1.2. Về pipeline và quy trình thực nghiệm 37
3.1.3. Về mô hình và khả năng học đặc trưng 37
3.1.4. Về kết quả thực nghiệm và so sánh mô hình 37
3.2. HẠN CHẾ 38
3.3. HƯỚNG PHÁT TRIỂN 38

DANH MỤC CÁC BẢNG BIỂU

Bảng 1.1. Bảng giải thích các mũi tên biểu thị trong sơ đồ kiến trúc U-Net 7
Bảng 2.1. Bảng thống kê diện tích vùng đối tượng.....22
Bảng 2.2. Bảng mô tả 4 mức encoder. 26
Bảng 2.3. Bảng kết quả đánh giá mô hình trên tập Test mô hình U - Net 32
Bảng 2.4. Bảng kết quả đánh giá mô hình trên tập Test mô hình FCN – ResNet34.....34
Bảng 2.5. Bảng so sánh kết quả của hai mô hình.....35

DANH MỤC CÁC HÌNH VẼ

Hình 1.1. Minh họa phân biệt giữa Object Detection và Image Segmentation.....3
Hình 1.2. Minh họa Semantic Segmentation, Instance Segmentation và Panoptic segmentation.....4
Hình 1.3. Cấu trúc cơ bản của mô hình mạng nơ-ron cho Image Segmentation. 6
Hình 1.4. Kiến trúc mạng U-Net 7
Hình 1.5. So sánh Convolution với Transposed Convolution.....8
Hình 1.6. Minh họa bước nhân tích chập và xử lý dịch chuyển stride với hai giá trị stride bằng 1 và 2.....9
Hình 1.7. Minh họa bước xử lý chồng chéo (overlap). 9
Hình 1.8. Minh họa bước áp dụng padding.....10
Hình 1.9. Giá trị Input và Kernel cho hai ví dụ tính toán quá trình Transposed.....10
Hình 1.10. Minh họa các bước tính Transposed Convolution cho ví dụ 1.1. 11
Hình 1.11. Minh họa các bước tính Transposed Convolution cho ví dụ 1.2. 11
Hình 1.12. Kiến trúc U-Net với 2 phần chính Encoder – Decoder. 11
Hình 1.13. Minh họa kiến trúc tổng quát của FCN - ResNet. 13
Hình 1.14. Hình minh họa công thức tính Dice Score 17
Hình 1.15. Hình minh họa công thức IoU. 18
Hình 2.1. Hình ảnh trực quan hóa lớp phủ kiểm tra nhãn sai/ lệch. 21
Hình 2.2. Biểu đồ phân phối dữ liệu. 22
Hình 2.3. Hình ảnh phát hiện trùng lặp dữ liệu giữa tập Train và Test.....23
Hình 2.4. Sơ đồ tóm tắt quy trình pipeline U-Net. 24
Hình 2.5. Kiến trúc mô hình U-Net. 25
Hình 2.6. Quy trình pipeline FCN – ResNet34 28
Hình 2.7. Kiến trúc mô hình FCN – ResNet34 29
Hình 2.8. Biểu đồ trực quan lịch sử huấn luyện mô hình U - Net 31
Hình 2.9. Hiện thị kết quả dự đoán trên tập Test mô hình U -Net 32
Hình 2.10. Hình ảnh dự đoán trên tập Test không Mask mô hình U - Net. 33
Hình 2.11. Biểu đồ trực quan lịch sử huấn luyện mô hình FCN – ResNet34 33
Hình 2.12. Hiện thị kết quả dự đoán trên tập Test mô hình FCN – ResNet34.....34
Hình 2.13. Hình ảnh dự đoán trên tập Test không Mask mô hình FCN – ResNet34. ..35

DANH MỤC CÁC KÍ HIỆU, CHỮ VIẾT TẮT

STT	Ký hiệu viết tắt	Viết đầy đủ
1	ADAS	Advanced Driver Assistance Systems
2	AR	Augmented Reality
3	CNN	Convolutional Neural Network
4	CT	Computed Tomography
5	DL	Deep Learning
6	FCN	Fully Convolutional Network
7	FC	Fully Connected
8	IoU	Intersection over Union
9	LiDAR	Light Detection and Ranging
10	MD5	Message Digest algorithm 5
11	mIoU	Mean Intersection over Union
12	MRI	Magnetic Resonance Imaging
13	PA	Pixel Accuracy
14	ReLU	Rectified Linear Unit
15	ResNet	Residual Network
16	U-Net	U-Net Architecture

LỜI CẢM ƠN

Lời đầu tiên, nhóm chúng em xin gửi lời cảm ơn chân thành đến Ban Giám hiệu Trường Đại học Kinh tế – Kỹ thuật Công nghiệp cùng quý Thầy/Cô trong Khoa Khoa học Ứng dụng đã tạo điều kiện thuận lợi về cơ sở vật chất và môi trường học tập tốt nhất cho chúng em trong suốt thời gian qua.

Đặc biệt, chúng em xin bày tỏ lòng biết ơn sâu sắc nhất tới **ThS. Trần Quốc Hưng** giảng viên trực tiếp giảng dạy học phần Học sâu. Thầy đã tận tình truyền đạt kiến thức nền tảng, định hướng đề tài và dành nhiều tâm huyết để hướng dẫn, giải đáp những thắc mắc cho nhóm trong suốt quá trình nghiên cứu và thực hiện tiểu luận. Những kiến thức quý báu và sự chỉ dẫn sát sao của Thầy không chỉ giúp chúng em hoàn thành tốt bài tiểu luận này mà còn là hành trang vững chắc cho chúng em trên con đường phát triển chuyên môn sau này.

Mặc dù nhóm đã nỗ lực cố gắng hết mình để tìm hiểu và hoàn thiện đề tài *"Nghiên cứu ứng dụng Học sâu trong bài toán Phân đoạn ảnh"*, tuy nhiên do giới hạn về thời gian và kinh nghiệm thực tế nên bài làm khó tránh khỏi những thiếu sót. Chúng em rất mong nhận được những ý kiến đóng góp, nhận xét quý báu từ Thầy để bài tiểu luận được hoàn thiện hơn cũng như rút ra được những bài học kinh nghiệm bổ ích.

Chúng em xin kính chúc Thầy dồi dào sức khỏe, hạnh phúc và gặt hái được nhiều thành công trong sự nghiệp trồng người.

Xin chân thành cảm ơn!

Hà Nội, ngày 12 tháng 12 năm 2025

Nhóm thực hiện

(Nhóm 2)

MỞ ĐẦU

Trong kỷ nguyên công nghệ 4.0, thị giác máy tính (Computer Vision) đã và đang trở thành một trong những lĩnh vực mũi nhọn của Trí tuệ nhân tạo, với khả năng ứng dụng rộng rãi từ xe tự hành, giám sát an ninh đến y tế thông minh. Một trong những bài toán nền tảng và thách thức nhất của thị giác máy tính là Phân đoạn ảnh (Image Segmentation). Khác với phân loại ảnh hay phát hiện đối tượng, phân đoạn ảnh yêu cầu sự hiểu biết sâu sắc về ngữ nghĩa của từng điểm ảnh (pixel), cho phép định vị chính xác đường biên và hình dạng của đối tượng.

Trong lĩnh vực y học, phân đoạn ảnh đóng vai trò đặc biệt quan trọng trong việc hỗ trợ các bác sĩ chẩn đoán và đưa ra phác đồ điều trị. Việc phân tách chính xác các vùng tổn thương, khối u hay các cơ quan nội tạng từ ảnh X-quang, CT, MRI hay ảnh soi da liễu giúp tính toán định lượng mức độ xâm lấn và theo dõi diễn tiến bệnh một cách khách quan. Tuy nhiên, việc thực hiện phân đoạn thủ công bởi con người thường tốn nhiều thời gian, công sức và dễ bị ảnh hưởng bởi yếu tố chủ quan.

Sự phát triển mạnh mẽ của Học sâu, đặc biệt là các mạng nơ-ron tích chập (CNN), đã mở ra hướng đi mới cho bài toán này với độ chính xác vượt trội. Nhận thức được tầm quan trọng đó, nhóm quyết định thực hiện đề tài "Nghiên cứu ứng dụng Học sâu trong bài toán Phân đoạn ảnh".

Mục tiêu của tiểu luận là tìm hiểu cơ sở lý thuyết về phân đoạn ảnh, nghiên cứu các kiến trúc mạng học sâu tiên tiến (U-Net, FCN-ResNet), và tiến hành thực nghiệm trên bộ dữ liệu ảnh y tế (A0-2025 Medical Image Segmentation) để phân đoạn vùng tổn thương da. Thông qua việc xây dựng, huấn luyện và so sánh hiệu quả giữa mô hình U-Net và FCN-ResNet34, nhóm mong muốn đưa ra những đánh giá thực tiễn về khả năng ứng dụng của các mô hình này trong hỗ trợ chẩn đoán y khoa.

Cấu trúc của bài tiểu luận bao gồm 3 chương chính:

Chương 1: Cơ sở lý thuyết.

Chương 2: Thực nghiệm.

Chương 3: Kết luận và hướng phát triển.

CHƯƠNG 1: CƠ SỞ LÝ THUYẾT

1.1. GIỚI THIỆU BÀI TOÁN PHÂN ĐOẠN ẢNH

1.1.1. Khái niệm

Image Segmentation (phân đoạn ảnh) là một nhiệm vụ quan trọng trong lĩnh vực thị giác máy tính, trong đó một bức ảnh được chia thành nhiều vùng khác nhau với mục tiêu đơn giản hóa hoặc thay đổi biểu diễn của bức ảnh thành một dạng có ý nghĩa hơn để dễ dàng phân tích. Image Segmentation thường được sử dụng để xác định vị trí các đối tượng hoặc đường biên, hay nói cách khác, đây là quá trình gán nhãn cho từng pixel trong ảnh, sao cho các pixel thuộc cùng một đối tượng hoặc khu vực sẽ được nhóm lại với nhau.

Image Segmentation và Object Detection (phát hiện đối tượng) đều có chung mục tiêu là xác định các vùng chứa đối tượng và gán nhãn cho chúng; tuy nhiên, Image Segmentation yêu cầu độ chính xác cao hơn. Khác với Object Detection, nơi đối tượng được định vị thông qua các hộp giới hạn (bounding boxes), Image Segmentation yêu cầu nhãn dự báo phải chính xác đến từng pixel trong ảnh. Điều này giúp chúng ta hiểu rõ hơn về nội dung bức ảnh, không chỉ dừng lại ở việc xác định vị trí các vật thể mà còn mô tả được hình dạng của chúng, cũng như gán từng pixel vào đúng vật thể tương ứng.

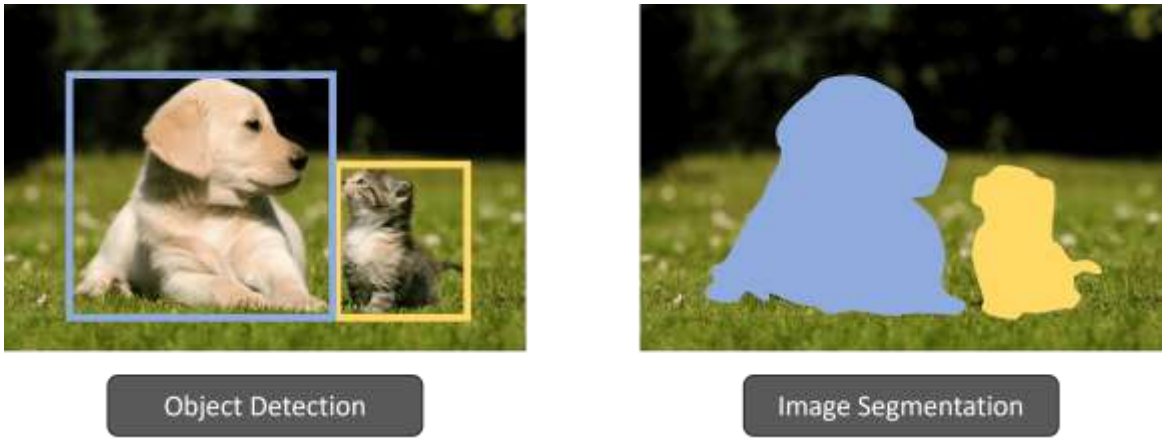

Hình 1.1. Minh họa phân biệt giữa Object Detection và Image Segmentation.

1.1.2. Phân loại

Image Segmentation được chia làm ba loại:

Semantic Segmentation: Gán nhãn cho từng pixel trong ảnh và nhóm các pixel có cùng ngữ nghĩa vào một lớp cụ thể. Quá trình này phân đoạn các vùng ảnh theo từng lớp khác nhau mà không phân biệt giữa các đối tượng riêng lẻ thuộc cùng một lớp.

Instance Segmentation: Phân đoạn các vùng ảnh chi tiết đến từng đối tượng trong mỗi lớp.

Panoptic Segmentation: Kết hợp giữa Semantic Segmentation và Instance Segmentation, trong đó mỗi đối tượng được phân đoạn với ranh giới rõ ràng, đồng thời danh tính và ý nghĩa của từng đối tượng trong ảnh được dự đoán chính xác.

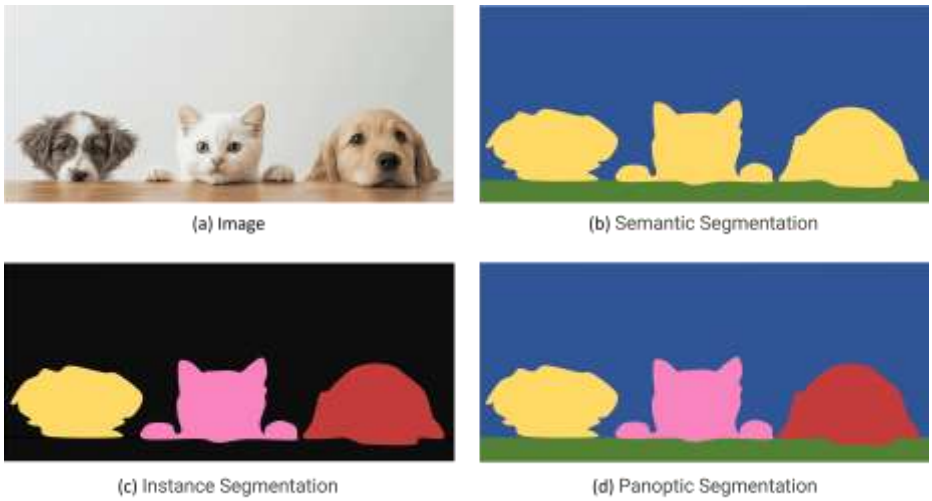

Hình 1.2. Minh họa Semantic Segmentation, Instance Segmentation và Panoptic segmentation.

1.1.3. Ứng dụng thực tiễn

Image Segmentation (phân đoạn ảnh) là kỹ thuật gán nhãn cho từng điểm ảnh để xác định chính xác vùng thuộc về một đối tượng hoặc một lớp ngữ nghĩa. Khác với phân loại ảnh (chỉ trả lời ảnh thuộc lớp nào) hay phát hiện đối tượng (khoanh vùng bằng hình chữ nhật), phân đoạn ảnh tạo ra "mặt nạ" (mask) cho biết ranh giới và hình dạng của đối tượng ở mức pixel. Nhờ độ chi tiết cao này, segmentation đặc biệt hữu ích trong các bài toán cần đo lường diện tích, thể tích, biên dạng, cũng như hỗ trợ ra quyết định dựa trên cấu trúc không gian của đối tượng.

Trong lĩnh vực y học, phân đoạn ảnh đóng vai trò quan trọng trong phân tích ảnh y khoa như X-quang, CT và MRI. Kỹ thuật này được dùng để tách cơ quan (gan, phổi, tim, não…) hoặc vùng tổn thương (khối u, nốt bất thường, vùng viêm…) nhằm hỗ trợ bác sĩ chẩn đoán và lập kế hoạch điều trị. Khi có mask chính xác, hệ thống có thể tính toán các chỉ số định lượng như diện tích/ thể tích khối u, mức độ xâm lấn, hoặc theo dõi thay đổi theo thời gian để đánh giá đáp ứng điều trị. Trong ảnh hiển vi, segmentation còn giúp tách và đếm tế bào, nhân tế bào, từ đó phục vụ nghiên cứu sinh học, xét nghiệm mô bệnh học và tự động hóa một số công đoạn phân tích vốn trước đây phải làm thủ công.

Trong xử lý ảnh vệ tinh và viễn thám, segmentation được sử dụng để phân loại lớp phủ bề mặt như đất trống, rừng, khu dân cư, mặt nước hoặc ruộng canh tác. Nhờ phân vùng chính xác, các cơ quan quản lý có thể lập bản đồ hiện trạng, giám sát biến đổi sử dụng đất, theo dõi suy giảm rừng, hoặc ước tính diện tích cây trồng theo mùa vụ. Segmentation cũng rất hữu ích trong đánh giá thiên tai, chẳng hạn xác định khu vực ngập lụt trên ảnh vệ tinh sau mưa bão, phát hiện vùng cháy rừng, hay ước lượng mức độ thiệt hại để phục vụ công tác cứu trợ và quy hoạch phục hồi. Ngoài ra, việc phân đoạn đường xá, cầu cống và tòa nhà còn hỗ trợ xây dựng và cập nhật bản đồ hạ tầng nhanh chóng trên phạm vi lớn.

Trong xe tự hành và các hệ thống hỗ trợ lái (ADAS), segmentation giúp xe "hiểu"

môi trường xung quanh một cách chi tiết hơn so với chỉ phát hiện hộp bao. Mô hình có thể phân đoạn vùng mặt đường có thể di chuyển (drivable area), vạch làn đường, lề đường, vỉa hè, cũng như các đối tượng tham gia giao thông như người đi bộ, xe máy, ô tô và biển báo. Thông tin ở mức pixel giúp hệ thống lập kế hoạch quỹ đạo an toàn, giữ làn, tránh vật cản và phản ứng phù hợp với ngữ cảnh (ví dụ giảm tốc trong khu vực đông người). Trong các hệ thống tiên tiến, segmentation còn được kết hợp với cảm biến LiDAR/radar để tăng độ tin cậy trong điều kiện ánh sáng yếu hoặc thời tiết xấu.

Ngoài ba lĩnh vực tiêu biểu trên, segmentation còn được ứng dụng rộng rãi trong sản xuất công nghiệp để kiểm tra chất lượng. Ví dụ, hệ thống thị giác máy tính có thể phân đoạn vết nứt, vết trầy xước, lỗ kim hoặc các lỗi bề mặt trên sản phẩm, từ đó tự động đánh giá mức độ lỗi và quyết định loại bỏ hay sửa chữa. Trong nông nghiệp chính xác, segmentation giúp phân biệt cây trồng và cỏ dại để phun thuốc chọn lọc, nhận diện vùng lá bệnh, hoặc xác định quả chín phục vụ thu hoạch tự động. Ở các ứng dụng tiêu dùng, phân đoạn ảnh được dùng để tách nền, làm mờ phông, thay nền video, hoặc tạo hiệu ứng AR như tách khuôn mặt và tóc để áp bộ lọc.

Tóm lại, điểm mạnh của Image Segmentation là khả năng mô tả đối tượng theo hình dạng và ranh giới cụ thể, nhờ đó hỗ trợ tốt cho các tác vụ đo lường định lượng, ra quyết định và tự động hóa quy trình trong nhiều lĩnh vực. Khi kết hợp với học sâu, segmentation ngày càng đạt độ chính xác cao và có thể triển khai trong các hệ thống thực tế, từ y tế đến giao thông thông minh và giám sát môi trường.

1.1.4. Phương pháp phân đoạn ảnh

Trong bài toán phân đoạn ảnh, các hướng tiếp cận có thể được chia thành hai nhóm chính: phương pháp truyền thống và phương pháp hiện đại dựa trên học sâu. Hai nhóm này khác nhau chủ yếu ở cách trích xuất đặc trưng và cách xác định ranh giới, vùng đối tượng trong ảnh.

1.1.4.1. Phương pháp truyền thống

Với phương pháp truyền thống, việc phân đoạn thường dựa trên các quy tắc và đặc trưng được thiết kế thủ công. Các kỹ thuật phổ biến bao gồm:

- Phân ngưỡng (Thresholding) để chia điểm ảnh thành các lớp dựa trên cường độ.
- Phân cụm (Clustering) như K-means để nhóm các điểm ảnh có đặc trưng tương đồng.
- Phân đoạn theo vùng (Region-based Segmentation) dựa vào sự tương đồng về màu sắc hoặc kết cấu.
- Phân đoạn theo cạnh (Edge-based Segmentation) để xác định ranh giới của các đối tượng trong hình ảnh.

Tuy nhiên, các phương pháp này thường nhạy với nhiễu, thay đổi ánh sáng, độ tương phản thấp và khó tổng quát khi đối tượng có hình dạng đa dạng hoặc bối cảnh

phức tạp đặc biệt trong các ảnh y tế, ảnh vệ tinh hoặc môi trường thực tế nhiều biến thiên.

1.1.4.2. Phương pháp hiện đại

Phương pháp hiện đại trong phân đoạn ảnh chủ yếu dựa trên học sâu (Deep Learning), đặc biệt là mạng nơ-ron tích chập (CNN). Thay vì dựa vào các đặc trưng được thiết kế thủ công như trong các phương pháp truyền thống, CNN học trực tiếp các biểu diễn đặc trưng từ dữ liệu thông qua quá trình huấn luyện. Nhờ khả năng học đặc trưng theo nhiều mức độ (từ cạnh, góc ở mức thấp đến hình dạng, cấu trúc ở mức cao), mô hình học sâu có thể thích nghi tốt hơn với sự đa dạng của ảnh, giảm ảnh hưởng của nhiễu và cho kết quả phân đoạn ổn định hơn trong những bối cảnh phức tạp.

Nhiều mô hình segmentation hiện đại được xây dựng theo kiến trúc encoder–decoder. Encoder có nhiệm vụ trích xuất đặc trưng và nén thông tin bằng cách giảm dần kích thước không gian (downsampling), giúp mô hình nắm bắt được ngữ nghĩa và bối cảnh của đối tượng. Sau đó, decoder khôi phục dần độ phân giải (upsampling) để tạo ra mặt nạ phân đoạn (segmentation mask) có kích thước tương ứng với ảnh đầu vào. Kiến trúc này cho phép mô hình vừa hiểu nội dung tổng quát của ảnh, vừa tái tạo được ranh giới đối tượng ở mức pixel, từ đó nâng cao độ chính xác phân đoạn.

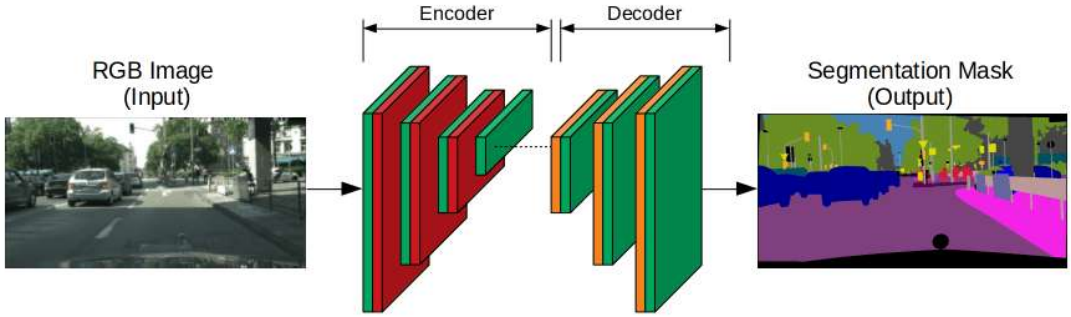

Hình 1.3. Cấu trúc cơ bản của mô hình mạng nơ-ron cho Image Segmentation.

Trong số các mô hình tiêu biểu, FCN (Fully Convolutional Network) là hướng tiếp cận chuyển bài toán phân loại sang dự đoán theo pixel bằng cách sử dụng hoàn toàn các lớp tích chập, đồng thời kết hợp cơ chế phóng to đặc trưng để tạo mask đầu ra. Khi sử dụng ResNet làm encoder, mô hình FCN–ResNet có khả năng trích xuất đặc trưng mạnh và phù hợp cho nhiều bài toán phân đoạn. Bên cạnh đó, U-Net là kiến trúc encoder–decoder đối xứng nổi bật với các skip connection giúp truyền thông tin chi tiết từ encoder sang decoder, nhờ vậy bảo toàn tốt thông tin không gian và cải thiện chất lượng biên, đặc biệt hiệu quả khi đối tượng cần phân đoạn có kích thước nhỏ hoặc biên mờ.

Tóm lại, dù yêu cầu dữ liệu gán nhãn và tài nguyên tính toán lớn hơn so với phương pháp truyền thống, các phương pháp học sâu mang lại độ chính xác cao và khả năng tổng quát tốt hơn trong nhiều bài toán thực tế. Vì vậy, trong đề tài này, nhóm phương pháp hiện đại được lựa chọn để xây dựng và đánh giá hai mô hình: FCN–ResNet và U-Net.

1.2. CÁC MÔ HÌNH HỌC SÂU SỬ DỤNG

1.2.1. Mô hình U-Net

U-Net là một mạng nơ-ron tích chập được thiết kế ban đầu cho phân đoạn ảnh y sinh. Kiến trúc của U-Net bao gồm 2 phần chính là encoder và decoder đối xứng nhau với hình dạng giống chữ U.

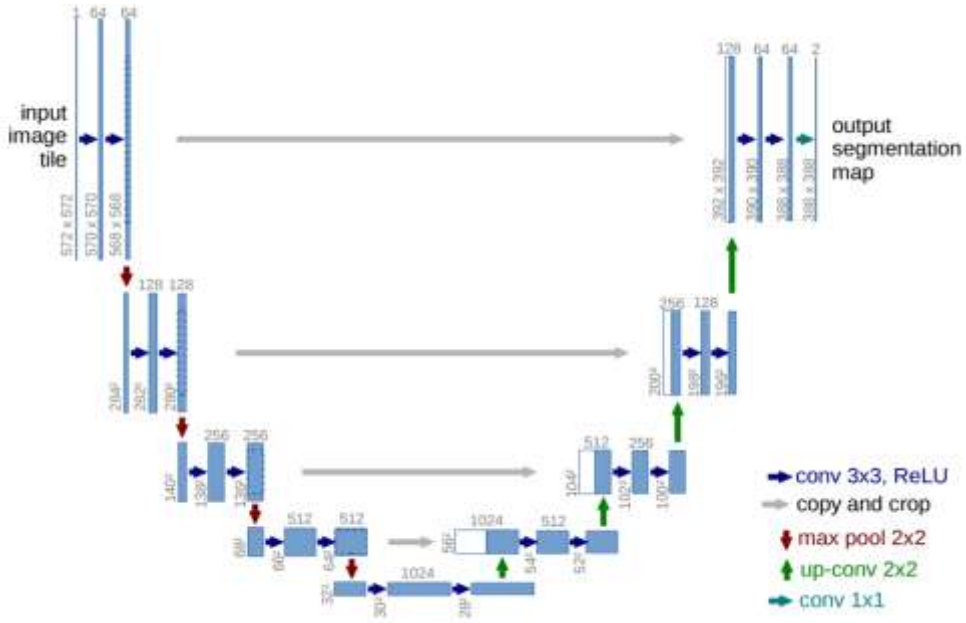

Hình 1.4. Kiến trúc mạng U-Net

Hình trên mô tả kiến trúc mạng U-Net, trong đó:

- Mỗi hình chữ nhật màu xanh biểu thị một multi-channel feature map.
- Số lượng channels được ghi chú ở phía trên hình chữ nhật.
- Kích thước x-y được cung cấp ở góc dưới bên trái của hình chữ nhật.
- Các hình chữ nhật màu trắng đại diện cho các feature maps được sao chép.

Các mũi tên biểu thị các operations khác nhau:

Bảng 1.1. Bảng giải thích các mũi tên biểu thị trong sơ đồ kiến trúc U-Net

Mũi tên	Ý nghĩa
	Conv layer 3x3, ReLU
	Skip Connections (có crop)
	Max Pooling 2x2
	Transposed Convolution
	Conv layer 1x1

1.2.1.1. Skip Connections

U-Net lần đầu tiên giới thiệu skip connections trong Deep Learning như một giải pháp hiệu quả để khắc phục mất mát thông tin trong quá trình downsampling, thường gặp trong các khối mã hóa (encoder) của kiến trúc encoder-decoder. Skip connections là các kết nối trực tiếp từ encoder đến decoder mà không cần đi qua bottleneck, giúp giảm thiểu mất mát dữ liệu do các phương pháp aggressive pooling và downsampling gây ra.

Việc sử dụng skip connections giúp khắc phục vấn đề mất thông tin ở spatial dimension. Nếu chỉ dựa vào feature map từ bottleneck để xây dựng lại feature map có độ phân giải cao, nhiều chi tiết về vị trí pixel sẽ bị mất. Nhờ các kết nối này, thông tin từ phần encoder được truyền trực tiếp sang decoder, hỗ trợ việc tái tạo vị trí pixel chính xác hơn.

1.2.1.2. Transposed Convolution

Convolution là một phép toán cơ bản trong xử lý dữ liệu, đặc biệt là trong mạng nơ-ron tích chập (CNN). Phép toán này sử dụng một kernel (bộ lọc) trượt qua dữ liệu đầu vào, tính tích chập để tạo ra bản đồ đặc trưng (feature map). Kết quả thường có kích thước nhỏ hơn, giúp trích xuất các đặc trưng cục bộ quan trọng như cạnh, góc hoặc mẫu hình.

Trong khi Convolution giảm kích thước không gian của dữ liệu, Transposed Convolution (hay còn gọi là Deconvolution) thực hiện ngược lại: nó mở rộng dữ liệu đầu vào. Đây là một kỹ thuật phổ biến trong các bài toán như Image Generation hoặc Image Segmentation, nơi cần khôi phục dữ liệu về kích thước ban đầu hoặc tạo dữ liệu có độ phân giải cao hơn.

Trong Convolution tiêu chuẩn, kích thước không gian của feature map được giảm bằng cách áp dụng kernel có kích thước cố định, kết hợp với stride và padding. Ngược lại, Transposed Convolution thực hiện chức năng mở rộng kích thước không gian của feature map bằng cách áp dụng kernel lên đầu vào, đồng thời điều chỉnh kích thước output thông qua stride và padding. Có thể hiểu, Transposed Convolution là quá trình ngược của Convolution thông thường, trong đó mỗi feature được ánh xạ thành các pixel của ảnh, thay vì ánh xạ các pixel thành feature như trong Convolution tiêu chuẩn (hình dưới đây minh họa sự khác biệt giữa hai quá trình này).

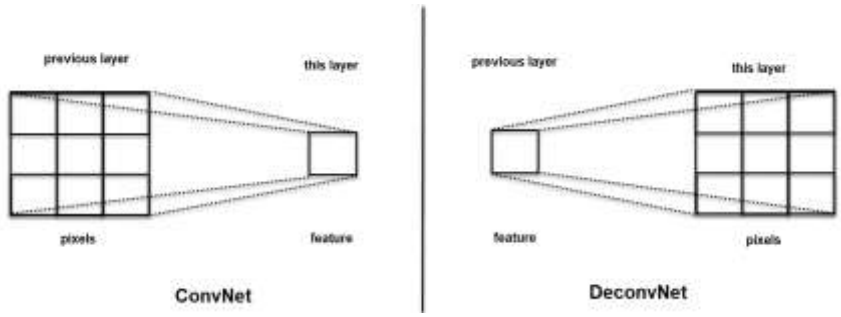

Hình 1.5. So sánh Convolution với Transposed Convolution

So với các phương pháp upsampling truyền thống như Nearest Neighbors, Bi-Linear Interpolation hay Max-Unpooling, Transposed Convolution vượt trội hơn nhờ khả năng học các tham số từ dữ liệu, giúp khôi phục thông tin không gian một cách chi tiết và chính xác hơn.

Quy trình thực hiện Transposed Convolution:

1. Nhân tích chập và xử lý dịch chuyển stride:

- Mỗi phần tử trong input feature map được nhân với kernel, sau đó kết quả được đặt vào vị trí tương ứng trên output feature map.
- Với stride = s, kết quả sẽ dịch chuyển s pixel sau mỗi lần tính toán, và stride lớn sẽ làm tăng kích thước của output.

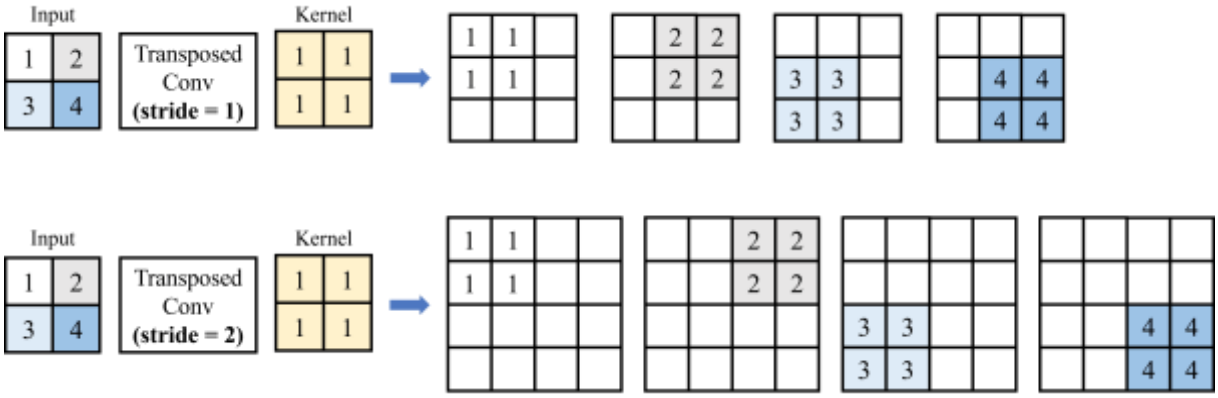

Hình 1.6. Minh họa bước nhân tích chập và xử lý dịch chuyển stride với hai giá trị stride bằng 1 và 2.

2. Xử lý chồng chéo (overlap): Khi kích thước stride nhỏ hơn kích thước kernel, các vùng trên ma trận kết quả sẽ bị chồng lên nhau. Trong trường hợp này, các giá trị tại các vị trí chồng chéo sẽ được cộng lại để tạo thành giá trị cuối cùng tại vị trí đó.

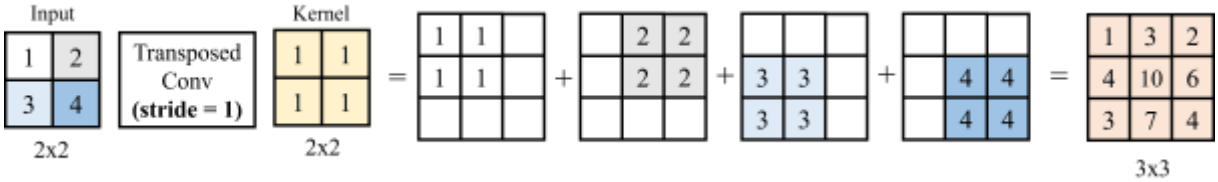

Hình 1.7. Minh họa bước xử lý chồng chéo (overlap).

3. Áp dụng padding:

- Padding được thêm vào để đảm bảo kích thước output phù hợp.
- Với padding = p, tiến hành loại bỏ p hàng và cột ở 4 cạnh (trên, dưới, trái, phải) của kết quả đầu ra. Lưu ý:
  - Khi padding = (p, q): bỏ đi p hàng đầu tiên và cuối cùng (trên, dưới); q cột đầu tiên và cuối cùng (trái, phải) của output.
  - Khi padding = p: đây là cách viết rút gọn, tương đương với padding = (p, p).

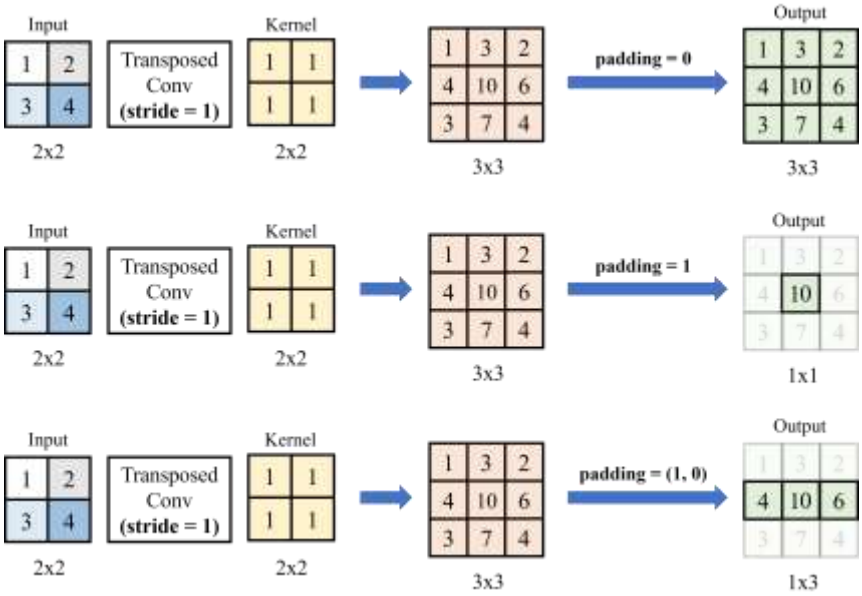

Hình 1.8. Minh họa bước áp dụng padding

- Công thức tổng quát để xác định kích thước output:

$$\text{Height: Hout} = (m - 1) \cdot s - 2p + (h - 1) + 1 \qquad (1.1)$$

$$\text{Width: Wout} = (n - 1) \cdot t - 2q + (k - 1) + 1 \qquad (1.2)$$

Trong đó:

- m x n: kích thước input.
- h x k: kích thước kernel.
- s x t: kích thước stride.
- p x q: kích thước padding.

Ví dụ minh họa:

Để hiểu rõ hơn các bước tính toán trong quá trình Transposed Convolution, chúng ta sẽ cùng thực hiện hai ví dụ với input và kernel được mô tả trong *Hình 1-9*.

- Input: Một encoded feature map kích thước 2x2.
- Kernel có kích thước 2x2.

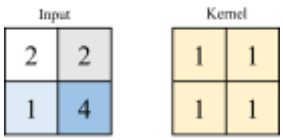

Hình 1.9. Giá trị Input và Kernel cho hai ví dụ tính toán quá trình Transposed

Ví dụ 1.1 : Với stride = 1 và padding = 0.

Đầu tiên, lấy từng pixel input nhân với kernel (nhân với từng phần tử). Với stride = 1, di chuyển kết quả của mỗi lần nhân pixel với kernel sang 1 pixel.

Sau khi thực hiện nhân tích chập, vì stride có kích thước nhỏ hơn kernel nên cần cộng các giá trị chồng chéo (overlap) lại với nhau. Trong trường hợp này, vì padding = 0 nên không loại bỏ hàng hay cột nào ở output. *Hình 1-10* dưới đây minh họa cho quá

trình tính Transposed Convolution cho ví dụ đầu tiên:

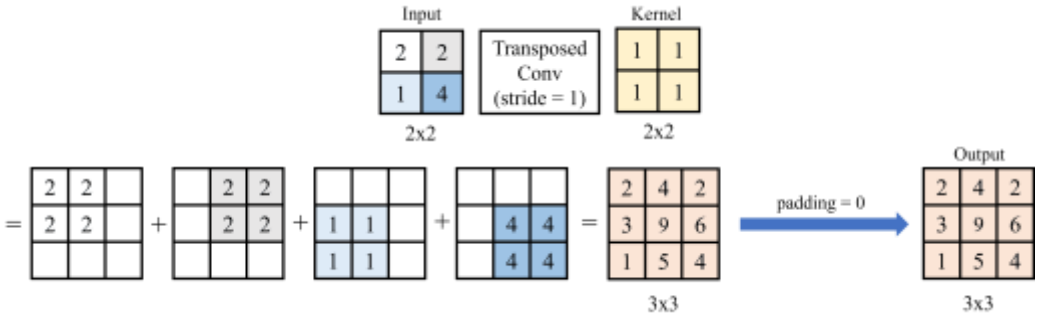

Hình 1.10. Minh họa các bước tính Transposed Convolution cho ví dụ 1.1.

Ví dụ 1.2: Với stride = 2 và padding = 1.

Đầu tiên, lấy từng pixel input nhân với kernel (nhân với từng phần tử). Với stride = 2, di chuyển kết quả của mỗi lần nhân pixel với kernel sang 2 pixel.

Sau khi thực hiện nhân chập, các giá trị không bị overlap vì kích trước của stride không nhỏ hơn kích thước kernel.

Với padding = 1, tiến hành loại bỏ 1 hàng và cột ở 4 cạnh (trên, dưới, trái, phải) của kết quả đầu ra. *Hình 1-11* dưới đây minh họa trình tính Transpose Convolution cho ví dụ 1.2 :

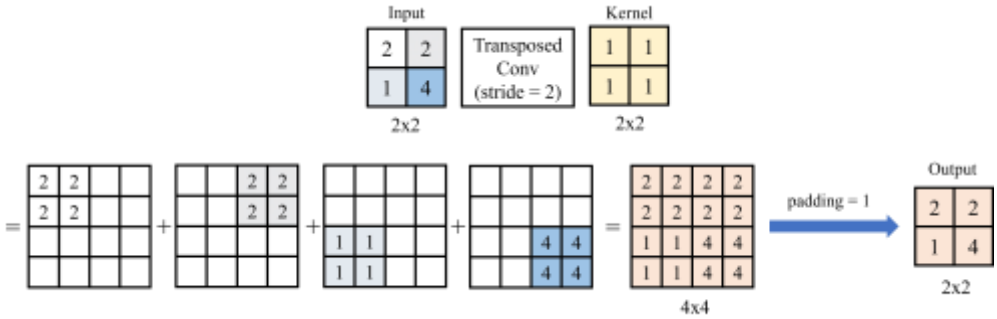

Hình 1.11. Minh họa các bước tính Transposed Convolution cho ví dụ 1.2.

1.2.1.3. Encoder

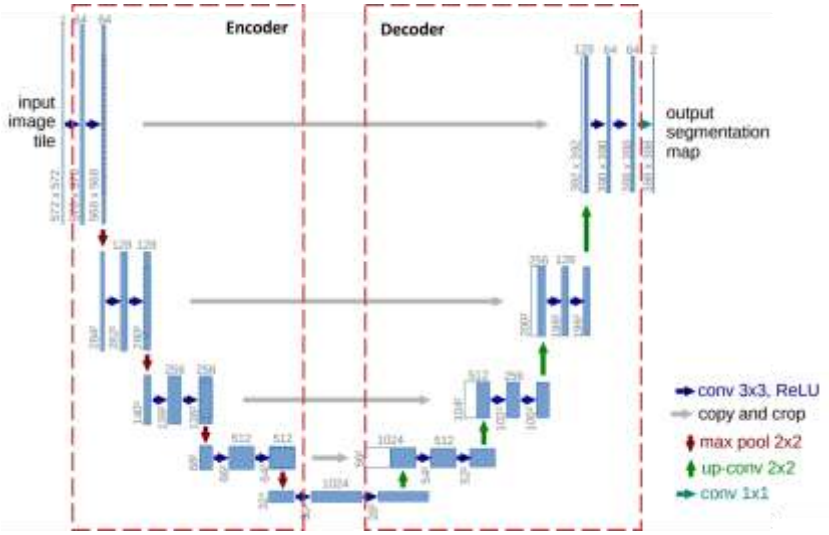

Hình 1.12. Kiến trúc U-Net với 2 phần chính Encoder – Decoder.

Dựa vào *Hình 1-12*, phần encoder bao gồm các lớp Conv và MaxPooling thông thường. Khi đi từ trên xuống dưới, kích thước width x height giảm, trong khi depth tăng lên (depth của output mỗi lớp được ghi ở trên đỉnh của hình chữ nhật, còn kích thước width và height được ghi dọc theo hình chữ nhật).

Encoder được thiết kế với mục tiêu trích xuất các đặc trưng quan trọng từ ảnh đầu vào thông qua các lớp convolution và pooling. Quá trình này không chỉ giúp nhận diện các đặc trưng quan trọng mà còn giảm dần kích thước không gian của ảnh, đồng thời giữ lại những thông tin đặc trưng cần thiết cho các bước xử lý tiếp theo trong mô hình.

1.2.1.4. Decoder

Phần này được thiết kế ngược lại với encoder vì nó làm tăng kích thước width x height, đồng thời giảm depth. Để thực hiện điều này, ta sử dụng Transposed Convolution. Tại mỗi giai đoạn của decoder, layer đối xứng tương ứng của encoder sẽ được crop và concatenate lại. Từ *Hình 1-12*, ta có thể thấy rõ cách thức hoạt động của decoder, với các bước thực hiện tăng dần kích thước không gian và tái tạo lại thông tin đã bị nén trong encoder.

Ngoài ra, kiến trúc U-Net không sử dụng lớp fully connected (FC) ở phần cuối, điều này tạo ra sự khác biệt so với các mô hình Deep Learning truyền thống. Trong các mô hình end-to-end thông thường, lớp FC sẽ kết nối các đặc trưng đã được trích xuất qua các lớp convolution để đưa ra kết quả dự đoán cuối cùng. Tuy nhiên, U-Net, việc kết nối các đặc trưng và tạo ra kết quả dự đoán được thực hiện thông qua phần up-sampling ở nửa thứ hai của "chữ U" (decoder).

1.2.1.5. Loss Funtion

Đây là bài toán phân lớp cho các pixels nên loss function sẽ bằng tổng cross entropy của các pixels trong ảnh.

1.2.2. Mô hình FCN – ResNet

FCN ResNet là một kiến trúc mạng nơ ron học sâu được xây dựng dựa trên sự kết hợp giữa Fully Convolutional Network (FCN) và mạng ResNet (Residual Network) làm backbone trích xuất đặc trưng. FCN là một trong những mô hình đầu tiên đề xuất việc thực hiện bài toán phân đoạn ảnh hoàn toàn bằng các lớp tích chập (convolution), loại bỏ hoàn toàn các lớp fully connected vốn làm mất thông tin không gian của ảnh. Nhờ đặc điểm này, FCN có khả năng tạo ra bản đồ phân đoạn ở mức điểm ảnh với kích thước tương ứng ảnh đầu vào.

Khi FCN được kết hợp với các biến thể của ResNet như ResNet34, ResNet50 hoặc ResNet101, mô hình được gọi chung là FCN ResNet. Trong kiến trúc này, ResNet đóng vai trò backbone (encoder mở rộng), chịu trách nhiệm trích xuất các đặc trưng từ ảnh đầu vào ở nhiều mức trừu tượng khác nhau. Nhờ các residual blocks sâu và cơ chế skip connection nội tại của ResNet, FCN ResNet có khả năng học được các đặc trưng ngữ nghĩa mạnh, giúp cải thiện đáng kể hiệu suất phân đoạn, đặc biệt trên các tập dữ liệu có

cấu trúc phức tạp như ảnh y tế, ảnh viễn thám hoặc ảnh sinh học.

Về mặt kiến trúc tổng thể, FCN ResNet gồm hai thành phần chính:

- Backbone ResNet (Encoder): trích xuất đặc trưng đa mức từ ảnh đầu vào.
- Segmentation Head (Decoder): đưa các đặc trưng này về đúng kích thước không gian của ảnh đầu ra thông qua các kỹ thuật upsampling.

So với các mô hình phân đoạn khác như U Net, FCN ResNet có phần decoder đơn giản hơn nhưng bù lại sở hữu encoder rất mạnh nhờ backbone ResNet sâu, giúp mô hình học tốt ngữ cảnh toàn cục của ảnh.

1.2.2.1. Kiến trúc tổng quan của mô hình FCN ResNet

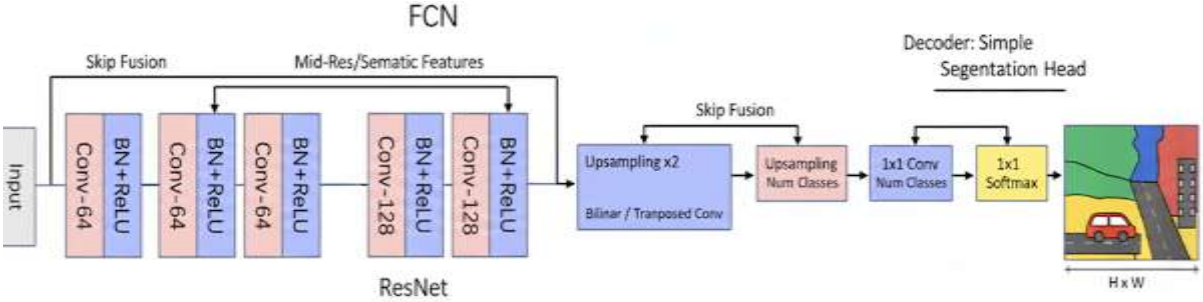

Hình 1.13. Minh họa kiến trúc tổng quát của FCN - ResNet.

Kiến trúc tổng quan của FCN ResNet được xây dựng theo hướng encoder–decoder, trong đó ResNet đảm nhiệm vai trò encoder và một segmentation head đơn giản đảm nhiệm vai trò decoder. Ảnh đầu vào trước hết được đưa qua các lớp tích chập ban đầu của ResNet để trích xuất các đặc trưng mức thấp như cạnh, đường biên và kết cấu cục bộ. Khi đi sâu hơn vào các residual blocks, mô hình dần học được các đặc trưng mức cao hơn, mang tính ngữ nghĩa và cấu trúc toàn cục của ảnh.

Một điểm quan trọng trong kiến trúc FCN ResNet là việc sử dụng các feature map ở nhiều tầng khác nhau của ResNet. Thay vì chỉ sử dụng feature map cuối cùng (có độ phân giải rất thấp), FCN ResNet kết hợp các feature map từ các tầng trung gian thông qua cơ chế fusion dạng skip like. Cách làm này giúp mô hình tận dụng được cả thông tin chi tiết hình học lẫn thông tin ngữ nghĩa sâu, từ đó cải thiện chất lượng phân đoạn.

Sau khi hợp nhất các feature map, mô hình sử dụng các kỹ thuật upsampling như bilinear upsampling hoặc transposed convolution để mở rộng kích thước feature map về lại kích thước ảnh ban đầu. Cuối cùng, một lớp convolution 1×1 được sử dụng để chuyển đổi số kênh đặc trưng thành số lớp phân đoạn cần dự đoán.

So với U Net, kiến trúc FCN ResNet có decoder đơn giản hơn, không có cấu trúc đối xứng hoàn chỉnh. Tuy nhiên, nhờ encoder rất mạnh, FCN ResNet vẫn đạt hiệu quả cao trong nhiều bài toán phân đoạn, đặc biệt là các bài toán yêu cầu hiểu ngữ cảnh hơn là tái tạo biên chi tiết.

1.2.2.2. Backbone ResNet (Bộ trích xuất đặc trưng chính)

ResNet (Residual Network) là một trong những kiến trúc CNN quan trọng và có

ảnh hưởng lớn trong lĩnh vực học sâu, đặc biệt nhờ cơ chế residual connection cho phép huấn luyện các mạng rất sâu mà không gặp hiện tượng suy giảm gradient. Trong FCN ResNet, ResNet đóng vai trò backbone, chịu trách nhiệm trích xuất đặc trưng từ ảnh đầu vào.

Cốt lõi của ResNet là Residual Block, được mô tả bởi công thức:

$$\text{Output} = F(x) + x \qquad (1.3)$$

Trong đó x là đầu vào của block, còn F(x) là ánh xạ học được thông qua một chuỗi các lớp convolution, batch normalization và hàm kích hoạt ReLU. Việc cộng trực tiếp x vào đầu ra giúp gradient lan truyền hiệu quả hơn trong quá trình huấn luyện, từ đó tránh hiện tượng vanishing gradient.

Mỗi residual block trong ResNet thường bao gồm các lớp convolution 3×3 hoặc 1×1, kết hợp với batch normalization và ReLU. Khi đi qua các block liên tiếp, ResNet học được các đặc trưng ngày càng trừu tượng hơn: các block đầu tập trung vào cạnh và đường biên, các block giữa học hình dạng và cấu trúc, trong khi các block sâu nhất nắm bắt ngữ cảnh toàn cục của ảnh.

Trong FCN ResNet, backbone ResNet hoạt động như một encoder mạnh mẽ, nén ảnh đầu vào thành các tensor đặc trưng giàu thông tin. So với encoder của U Net truyền thống, encoder dựa trên ResNet thường sâu hơn và có khả năng tổng quát hóa tốt hơn, đặc biệt khi được khởi tạo từ các trọng số pretrained trên tập ImageNet.

1.2.2.3. Skip Fusion (Kết hợp đặc trưng đa mức)

Một trong những yếu tố quan trọng giúp FCN ResNet đạt hiệu quả cao là cơ chế kết hợp đặc trưng đa mức (skip fusion). Trong quá trình trích xuất đặc trưng, các feature map sâu của ResNet chứa thông tin ngữ nghĩa rất mạnh nhưng lại có độ phân giải thấp, trong khi các feature map nông có độ phân giải cao hơn nhưng thông tin ngữ nghĩa còn hạn chế.

FCN ResNet giải quyết vấn đề này bằng cách kết hợp các feature map từ nhiều tầng khác nhau của backbone ResNet. Việc kết hợp có thể được thực hiện thông qua phép cộng (element wise addition) hoặc phép nối kênh (concatenation). Nhờ đó, mô hình có thể đồng thời tận dụng được thông tin chi tiết hình học và thông tin ngữ cảnh sâu.

So với skip connection trong U Net, skip fusion trong FCN có cấu trúc đơn giản hơn, không yêu cầu một decoder đối xứng hoàn chỉnh. Tuy nhiên, cách làm này vẫn giúp cải thiện đáng kể khả năng tái tạo biên và độ chính xác phân đoạn, đặc biệt trong các bài toán phân đoạn ngữ nghĩa nơi cấu trúc đối tượng tương đối lớn và đồng nhất.

1.2.2.4. Decoder

Khác với U Net, decoder trong FCN ResNet có cấu trúc rất gọn nhẹ. Sau khi trích xuất và hợp nhất các feature map, mô hình sử dụng một lớp convolution 1×1 để ánh xạ số kênh đặc trưng về số lớp phân đoạn cần dự đoán. Lớp này đóng vai trò như một bộ

phân loại cho từng điểm ảnh.

Tiếp theo, mô hình sử dụng các kỹ thuật upsampling để đưa feature map về đúng kích thước không gian của ảnh đầu vào. Bilinear upsampling là phương pháp được sử dụng phổ biến nhất do không yêu cầu tham số học, tốc độ nhanh và ổn định. Trong một số trường hợp, transposed convolution cũng được sử dụng để học cách khôi phục biên chi tiết hơn, mặc dù phương pháp này có thể gây ra hiện tượng checkerboard artifacts nếu không được thiết kế cẩn thận.

Do ResNet giảm kích thước ảnh đầu vào nhiều lần (thường là 1/32), decoder phải thực hiện upsampling tương ứng để đưa đầu ra về kích thước H×W ban đầu. Nhờ cấu trúc đơn giản, decoder của FCN ResNet có số lượng tham số ít, tốc độ suy luận nhanh và phù hợp với các hệ thống có tài nguyên tính toán hạn chế.

1.2.2.5. Ưu điểm của mô hình FCN-ResNet

FCN ResNet sở hữu nhiều ưu điểm nổi bật. Trước hết, mô hình có khả năng trích xuất đặc trưng rất mạnh nhờ backbone ResNet sâu và hiệu quả. Thứ hai, cấu trúc đơn giản của decoder giúp mô hình dễ huấn luyện, không yêu cầu tài nguyên GPU quá lớn. Ngoài ra, FCN ResNet có khả năng tổng quát hóa tốt trên dữ liệu ngoài domain, đặc biệt khi backbone được khởi tạo từ các trọng số pretrained.

Mô hình đặc biệt phù hợp với các bài toán phân đoạn có cấu trúc lớn và đồng nhất, nơi việc hiểu ngữ cảnh toàn cục quan trọng hơn việc tái tạo biên chi tiết. So với U Net, FCN ResNet thường nhẹ hơn và nhanh hơn, phù hợp cho các ứng dụng yêu cầu tốc độ.

1.2.2.6. Hạn chế của mô hình FCN ResNet

Bên cạnh các ưu điểm, FCN ResNet cũng tồn tại một số hạn chế. Do decoder đơn giản, khả năng tái tạo các chi tiết nhỏ và đường biên phức tạp của mô hình không tốt bằng U Net. Trong các bài toán phân đoạn vùng rất nhỏ, chẳng hạn như các tổn thương nhỏ trong ảnh y tế, FCN ResNet có thể bỏ sót chi tiết.

Ngoài ra, hiệu suất của mô hình phụ thuộc nhiều vào độ sâu của backbone ResNet. Các backbone sâu hơn như ResNet101 cho kết quả tốt hơn nhưng đồng thời làm tăng chi phí tính toán và thời gian huấn luyện. Vì vậy, trong thực tế, FCN ResNet thường được sử dụng song song với U Net hoặc các biến thể khác để so sánh hiệu suất.

1.2.2.7. Loss Function

FCN ResNet giải quyết bài toán phân loại từng điểm ảnh, do đó các hàm mất mát thường được sử dụng tương tự như trong U Net. Cross Entropy Loss là hàm mất mát phổ biến nhất, phù hợp cho các bài toán phân đoạn đa lớp. Tuy nhiên, trong các tập dữ liệu ảnh y tế, sự mất cân bằng giữa các lớp thường rất lớn, khiến Cross Entropy đơn thuần không đạt hiệu quả tối ưu.

Dice Loss được sử dụng để khắc phục vấn đề này bằng cách đo độ chồng lắp giữa vùng dự đoán và vùng ground truth. Trong nhiều nghiên cứu, việc kết hợp Cross Entropy Loss và Dice Loss đã cho thấy hiệu quả cao, giúp mô hình học tốt cả các vùng lớn lẫn

các vùng nhỏ, đồng thời cải thiện độ ổn định trong quá trình huấn luyện.

1.2.3. Các chỉ số đánh giá mô hình

Để định lượng hiệu quả của mô hình phân đoạn ảnh, báo cáo sử dụng hệ thống các chỉ số đánh giá tiêu chuẩn trong lĩnh vực thị giác máy tính, bao gồm: Pixel Accuracy, Precision, Recall, Dice Score, Intersection over Union (IoU) cho lớp đối tượng và Mean Intersection over Union (mIoU). Các chỉ số này được tính toán dựa trên sự so khớp giữa bản đồ phân đoạn dự đoán (Prediction) và nhãn thực tế (Ground Truth), qua đó phản ánh độ chính xác của mô hình từ cấp độ điểm ảnh đến cấp độ vùng đối tượng.

Trong bài toán phân đoạn ảnh, trạng thái dự đoán của mỗi điểm ảnh được phân loại dựa trên ma trận nhầm lẫn (Confusion Matrix) gồm 4 thành phần:

- True Positive (TP): Điểm ảnh thuộc lớp đối tượng và mô hình dự đoán chính xác là đối tượng.
- True Negative (TN): Điểm ảnh thuộc lớp nền và mô hình dự đoán chính xác là nền.
- False Positive (FP): Điểm ảnh thực tế là nền nhưng mô hình dự đoán nhầm là đối tượng (Lỗi báo động giả).
- False Negative (FN): Điểm ảnh thực tế là đối tượng nhưng mô hình dự đoán nhầm là nền (Lỗi bỏ sót).

Dựa trên các thành phần này, các chỉ số đánh giá cụ thể được xác định như sau:

1.2.3.1. Pixel Accuracy (Độ chính xác điểm ảnh)

Pixel Accuracy là chỉ số cơ bản nhất, đo lường tỷ lệ phần trăm các điểm ảnh được phân loại đúng trên toàn bộ ảnh.

$$\text{Pixel Accuracy} = \frac{\text{TP} + \text{TN}}{\text{TP} + \text{TN} + \text{FP} + \text{FN}} \qquad (1.4)$$

Đánh giá: Chỉ số này cho cái nhìn tổng quan về hiệu năng mô hình. Tuy nhiên, trong các bài toán thực tế (đặc biệt là ảnh y tế), hiện tượng mất cân bằng dữ liệu thường xuyên xảy ra khi diện tích nền chiếm đa số so với vùng đối tượng. Trong trường hợp đó, Pixel Accuracy có thể đạt giá trị rất cao ngay cả khi mô hình thất bại trong việc phát hiện đối tượng. Do đó, chỉ số này thường chỉ mang tính tham khảo và cần được xem xét cùng các độ đo chuyên sâu khác.

1.2.3.2. Precision (Độ chính xác dương)

Precision đo lường độ tin cậy của các dự đoán dương tính, hay tỷ lệ điểm ảnh thực sự là đối tượng trong số các điểm ảnh mà mô hình dự đoán là đối tượng.

$$\text{Precision} = \frac{\text{TP}}{\text{TP} + \text{FP}} \qquad (1.5)$$

Đánh giá: Precision cao đồng nghĩa với việc mô hình ít mắc lỗi dương tính giả (False Positive). Trong ngữ cảnh phân đoạn ảnh y tế, chỉ số này rất quan trọng để đảm

bảo không chẩn đoán nhầm các mô lành tính thành vùng tổn thương. Tuy nhiên, Precision không đánh giá được việc mô hình có bỏ sót đối tượng hay không, nên cần được phân tích song song với Recall.

1.2.3.3. Recall (Độ nhạy)

Recall đánh giá khả năng bao phủ của mô hình, đo lường tỷ lệ điểm ảnh đối tượng được mô hình phát hiện thành công trên tổng số điểm ảnh đối tượng thực tế.

$$\text{Recall} = \frac{\text{TP}}{\text{TP} + \text{FN}} \qquad (1.6)$$

Đánh giá: Recall phản ánh khả năng không bỏ sót vùng quan tâm. Đối với các bài toán y tế, đây thường là chỉ số tối quan trọng vì việc bỏ sót tổn thương (False Negative) có thể gây hậu quả nghiêm trọng hơn việc báo nhầm. Một mô hình có Recall cao chấp nhận đánh đổi một phần Precision để đảm bảo phát hiện tối đa các vùng bất thường.

1.2.3.4. Dice Score

Dice Score, hay Dice Similarity Coefficient (DSC), là chỉ số phổ biến hàng đầu trong phân đoạn ảnh y tế, đo lường mức độ tương đồng (overlap) giữa vùng dự đoán và vùng thực tế. Dice thực chất là trung bình điều hòa của Precision và Recall (tương đương F1-Score).

- Biểu diễn theo tập hợp (Lý thuyết hình học):

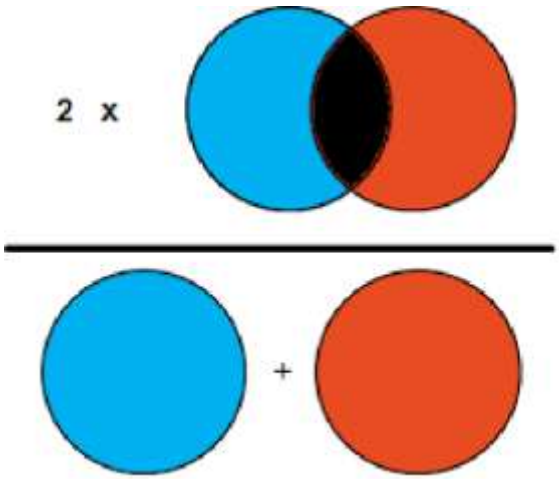

Hình 1.14. Hình minh họa công thức tính Dice Score

$$\text{Dice Score} = \frac{2 \times |A \cap B|}{|A| + |B|} \qquad (1.7)$$

Trong đó $|A \cap B|$ là diện tích vùng giao nhau, $|A|$ và $|B|$ lần lượt là diện tích vùng dự đoán và vùng thực tế.

- Biểu diễn theo ma trận nhầm lẫn (Tính toán thực nghiệm):

$$\text{Dice Score} = \frac{2 \times \text{TP}}{2 \times \text{TP} + \text{FP} + \text{FN}} \qquad (1.8)$$

Đánh giá: Giá trị Dice nằm trong khoảng [0, 1]. Ưu điểm vượt trội của Dice là khả năng xử lý tốt vấn đề mất cân bằng dữ liệu do công thức không phụ thuộc vào True Negative (vùng nền). Do đó, Dice tập trung trực tiếp vào khả năng khớp vùng đối tượng và thường được xem là thước đo chính trong nhiều nghiên cứu.

1.2.3.5. Intersection over Union (IoU - Object)

Intersection over Union (IoU), hay chỉ số Jaccard, đo lường tỷ lệ giữa diện tích phần giao (Intersection) và diện tích phần hợp (Union) của vùng dự đoán và vùng Ground Truth.

- Biểu diễn theo tập hợp (Lý thuyết hình học):

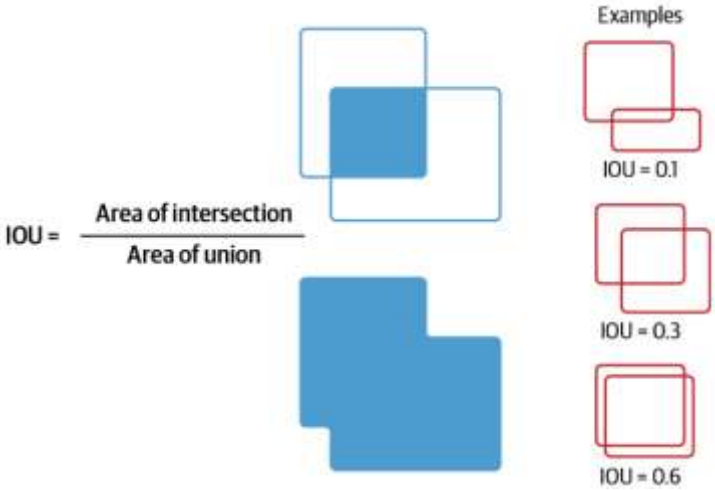

Hình 1.15. Hình minh họa công thức IoU.

$$\text{IoU} = \frac{|A \cap B|}{|A \cup B|} \qquad (1.9)$$

Trong đó:

- A: Vùng dự đoán bởi mô hình.
- B: Vùng nhãn thực tế.
- $|A \cap B|$: Diện tích phần giao giữa dự đoán và thực tế.
- $|A \cup B|$: Diện tích phần hợp của cả dự đoán và thực tế.

- Biểu diễn theo ma trận nhầm lẫn (Tính toán thực nghiệm):

$$\text{IoU} = \frac{\text{TP}}{\text{TP} + \text{FP} + \text{FN}} \qquad (1.10)$$

Đánh giá: Trong phạm vi báo cáo này, IoU (Object) được sử dụng để đánh giá riêng cho lớp đối tượng quan tâm. So với Dice, IoU là một chỉ số khắt khe hơn (thường có giá trị thấp hơn Dice trên cùng một kết quả) nhưng phản ánh chính xác chất lượng của việc khoanh vùng đối tượng.

1.2.3.6. Mean Intersection over Union (mIoU)

Đối với bài toán phân đoạn đa lớp, mIoU là chỉ số tổng quát được tính bằng trung bình cộng của IoU trên tất cả các lớp (bao gồm cả lớp nền và các lớp đối tượng).

$$\mathrm{mIoU} = \frac{1}{C}\sum_{i=1}^{C} \mathrm{IoU}_i \qquad (1.11)$$

Trong đó C là tổng số lượng lớp.

Đánh giá: mIoU cung cấp một đánh giá khách quan về hiệu năng tổng thể của mô hình trên toàn bộ tập dữ liệu, giảm thiểu tác động của sự chênh lệch số lượng mẫu giữa các lớp. Đây là chỉ số tiêu chuẩn để so sánh sức mạnh giữa các kiến trúc mạng khác nhau.

Nhận xét chung:

Việc kết hợp đa chiều các chỉ số Pixel Accuracy, Precision, Recall, Dice Score, IoU và mIoU cho phép đánh giá mô hình một cách toàn diện: từ độ chính xác tổng thể, khả năng định vị biên dạng đối tượng, đến sự cân bằng giữa việc phát hiện đúng và tránh báo sai. Cách tiếp cận này đảm bảo tính chặt chẽ khoa học, đặc biệt phù hợp với đặc thù dữ liệu thường mất cân bằng và yêu cầu độ chính xác cao như trong bài toán phân đoạn ảnh.

1.3. KẾT LUẬN CHƯƠNG

Chương 1 đã hệ thống hóa các cơ sở lý thuyết quan trọng liên quan đến bài toán phân đoạn ảnh y tế. Đã trình bày tổng quan về các phương pháp phân đoạn, đồng thời đi sâu phân tích kiến trúc của các mô hình học sâu tiên tiến như U-Net và mạng FCN kết hợp Backbone ResNet. Đây là những nền tảng kiến thức cốt lõi để xây dựng giải pháp tự động hóa việc khoanh vùng tổn thương.

Dựa trên những cơ sở lý thuyết này, Chương 2 sẽ đi sâu vào quá trình thực nghiệm cụ thể, bao gồm việc xử lý bộ dữ liệu, thiết lập quy trình huấn luyện và đánh giá hiệu quả của các mô hình đã đề xuất trên tập dữ liệu ảnh da liễu thực tế.

CHƯƠNG 2: THỰC NGHIỆM

2.1. CHUẨN BỊ DỮ LIỆU

2.1.1. Giới thiệu về bộ dữ liệu

Bộ dữ liệu được sử dụng trong đề tài là A0-2025 Medical Image Segmentation, được cung cấp trong khuôn khổ một cuộc thi trên nền tảng Kaggle. Đây là bộ dữ liệu thuộc lĩnh vực ảnh y tế bao gồm các ảnh soi da liễu, phục vụ cho bài toán phân đoạn vùng tổn thương sắc tố da, được xây dựng nhằm phục vụ cho bài toán phân đoạn ảnh (image segmentation) – một nhiệm vụ quan trọng trong xử lý ảnh và thị giác máy tính, đặc biệt trong các hệ thống hỗ trợ chẩn đoán.

Về mặt cấu trúc, bộ dữ liệu được tổ chức và phân chia thành hai thành phần chính là huấn luyện (Train) và kiểm thử (Test). Cấu trúc này được thiết kế theo tiêu chuẩn của bài toán phân đoạn ảnh có giám sát, đảm bảo tính tách biệt rõ ràng giữa dữ liệu dùng để xây dựng mô hình và dữ liệu dùng để đánh giá hiệu năng thực tế. Tổng cộng, bộ dữ liệu chứa 1.279 ảnh y tế, trong đó 1.087 ảnh có nhãn phân đoạn dành cho huấn luyện và 192 ảnh không nhãn dành cho kiểm thử.

Bộ dữ liệu này mô phỏng sát với điều kiện thực tế trong môi trường lâm sàng da liễu, nơi các yếu tố nhiễu và sự biến thiên của dữ liệu là không thể tránh khỏi. Cấu trúc dữ liệu với phần huấn luyện có nhãn và phần kiểm thử không nhãn đặt ra thách thức cho người tham gia trong việc xây dựng các mô hình phân đoạn có khả năng học tốt từ dữ liệu huấn luyện, đồng thời duy trì hiệu suất cao và ổn định trên các mẫu dữ liệu chưa từng được nhìn thấy trước đó. Việc xây dựng thành công mô hình phân đoạn có độ chính xác cao trên bộ dữ liệu này không chỉ chứng minh năng lực kỹ thuật mà còn mở ra tiềm năng ứng dụng thực tiễn trong hỗ trợ chẩn đoán da liễu, góp phần nâng cao chất lượng chăm sóc sức khỏe và phát hiện sớm các bệnh lý nguy hiểm như ung thư da.

2.1.2. Khám phá dữ liệu

2.1.2.1. Tổng quan về bộ dữ liệu

Bộ dữ liệu được chia thành hai tập huấn luyện (Train) và kiểm tra (Test) với số lượng cụ thể như sau:

- Tập Train: 1087 ảnh (Images) và 1087 nhãn (Masks).
- Tập Test: 192 ảnh.
- Cấu trúc thư mục: Dữ liệu được tổ chức rõ ràng theo cấu trúc Dataset/Train/Image, Dataset/Train/Mask và Dataset/Test/Image.
- Định dạng: Tạo overlay mẫu và hiển thị một vài ảnh để kiểm tra nhãn sai/ lệch kết quả cho thấy ảnh và mask khớp hoàn toàn về kích thước và số lượng trong tập Train.

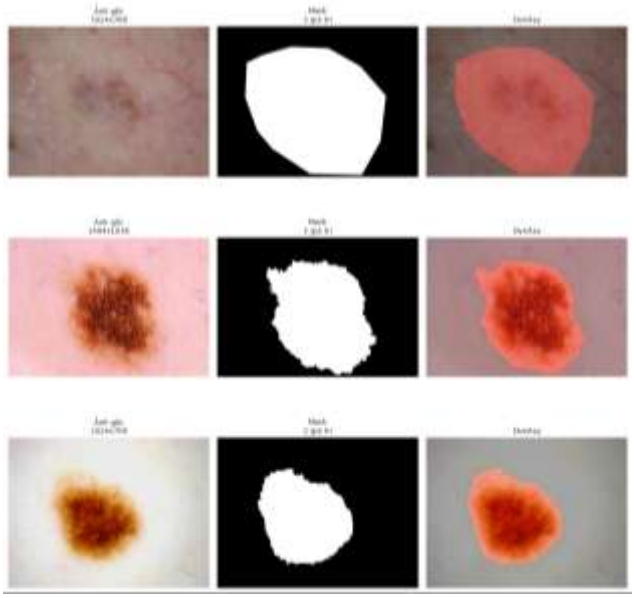

Hình 2.1. Hình ảnh trực quan hóa lớp phủ kiểm tra nhãn sai/ lệch.

2.1.2.2. Phân tích đặc trưng

Phân tích nhãn (Mask):

Dựa trên chỉ số mask_value_summary_sample = 1 từ kết quả kiểm tra rút ra được kết luận như sau:

- Loại bài toán: Ảnh mask chỉ chứa 2 giá trị: 0 (Nền) và 1 (Đối tượng).
- Mật độ đối tượng: 100% ảnh đều chứa đối tượng. Không có ảnh nào là nền trống. Điều này rất tốt vì mô hình sẽ luôn học được đặc trưng đối tượng trong mỗi lần lặp (iteration).

Phân tích kích thước ảnh (Độ phân giải):

Thống kê định lượng trên tập dữ liệu huấn luyện (N=1087) cho thấy sự phân hóa mạnh về độ phân giải (resolution), đặt ra thách thức đáng kể về vấn đề đa quy mô trong quá trình huấn luyện.

Cụ thể, kích thước 1024x768 chiếm tỷ trọng áp đảo với 569 ảnh (tương đương 52,3%), đóng vai trò là kích thước cơ sở cho bộ dữ liệu. Tuy nhiên, phổ kích thước có sự trải rộng lớn với sự xuất hiện của các nhóm ảnh độ phân giải cao, điển hình là 72 ảnh kích thước 3024x2016 (6,6%) và 67 ảnh kích thước 4288x2848 (6,2%). Nhóm này có số lượng điểm ảnh lớn gấp 8 đến 12 lần so với nhóm cơ sở. Ngoài ra, các kích thước tầm trung như 767x576 (58 ảnh), 3072x2304 (48 ảnh) và 2048x1536 (47 ảnh) cũng góp phần tạo nên sự đa dạng về không gian đặc trưng.

Bên cạnh sự chênh lệch về độ phân giải, sự không đồng nhất về tỷ lệ khung hình dao động giữa 4:3 (ở nhóm 1024x768, 2048x1536) và 3:2 (ở nhóm 3024x2016, 4288x2848) là một yếu tố rủi ro gây biến dạng hình học nếu áp dụng phương pháp resize cưỡng bức. Thực trạng này đòi hỏi chiến lược tiền xử lý cẩn trọng: ưu tiên phương pháp Resize with Padding để bảo toàn tỷ lệ gốc cho nhóm chủ đạo (chiếm >50%), hoặc kỹ thuật Sliding Window (Tiling) đối với nhóm ảnh độ phân giải cao (chiếm ~13%) nhằm

ngăn chặn việc mất mát thông tin chi tiết của các đối tượng nhỏ khi thu nhỏ về kích thước đầu vào của mô hình.

Phân tích kích thước đối tượng (Foreground Area)

Thống kê diện tích vùng đối tượng (số lượng pixel) cho thấy sự biến thiên rất lớn:

Bảng 2.1. Bảng thống kê diện tích vùng đối tượng

Chỉ số	Giá trị (Pixels)	Nhận xét
Min	~ 2109	Đối tượng rất nhỏ, dễ bị mất khi resize ảnh.
Mean	~ 424821	
Max	~ 4775054	Đối tượng chiếm gần hết khung hình.

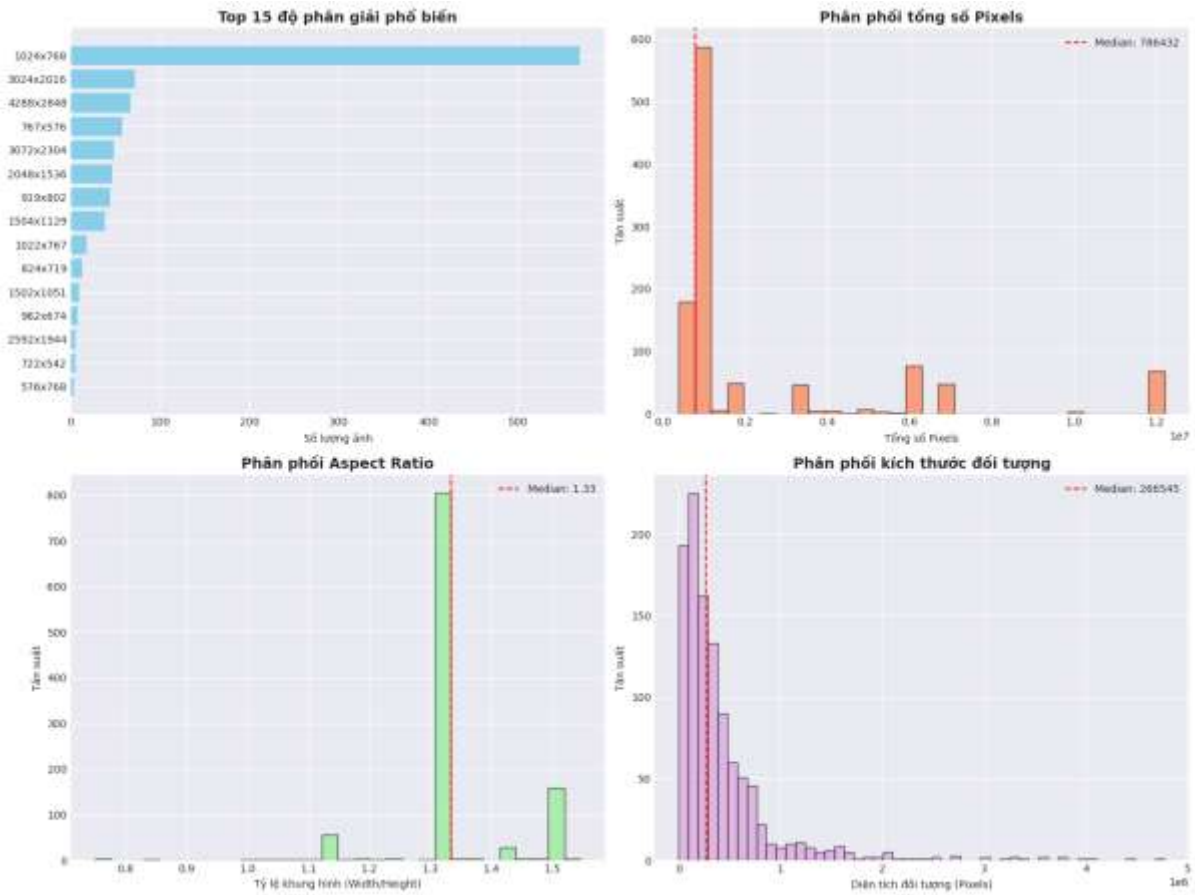

Hình 2.2. Biểu đồ phân phối dữ liệu.

Nhận xét: Quan sát biểu đồ phân phối kích thước đối tượng dữ liệu bị lệch phải. Đa số đối tượng có kích thước trung bình/nhỏ, nhưng tồn tại một số ít đối tượng khổng lồ kéo giá trị trung bình lên cao.

2.1.2.3. Đánh giá chất lượng dữ liệu

Trong quá trình kiểm tra chéo, đã phát hiện vấn đề rò rỉ dữ liệu nghiêm trọng cần xử lý :

Vấn đề: Trùng lặp dữ liệu giữa tập Train và Test.

Chi tiết: Ảnh 0000699.jpg (trong Train) giống hệt ảnh 0001163.jpg (trong Test) về mặt nội dung (mã băm MD5 trùng nhau).

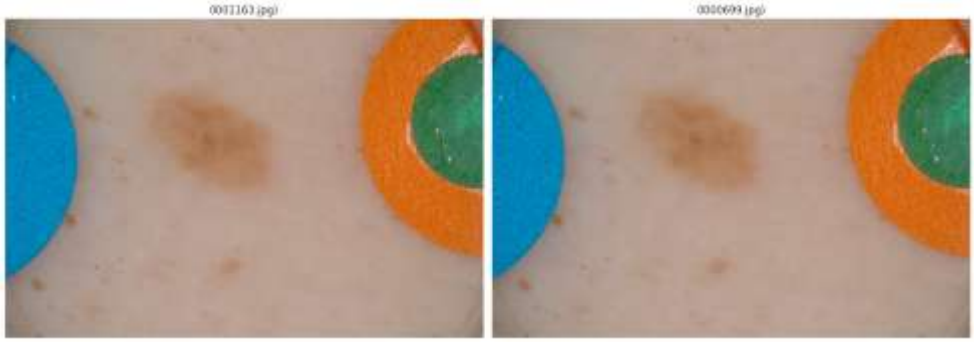

Hình 2.3. Hình ảnh phát hiện trùng lặp dữ liệu giữa tập Train và Test.

Rủi ro: Nếu giữ nguyên, mô hình sẽ "học thuộc lòng" đáp án của ảnh này trong lúc Train và khi gặp lại nó trong tập Test, kết quả sẽ cao một cách giả tạo.

2.1.3. Xử lý dữ liệu

Ở bước xử lý dữ liệu, nhóm thực hiện hai mục tiêu chính: làm sạch dữ liệu kiểm tra và chuẩn hóa đầu vào cho mô hình. Các ảnh bị trùng lặp với tập huấn luyện được loại khỏi tập kiểm tra bằng cách chuyển sang thư mục dự phòng nhằm đảm bảo tập kiểm tra phản ánh đúng khả năng tổng quát hóa. Về chuẩn hóa, nhóm đưa toàn bộ ảnh và mask về kích thước 256×256 theo phương pháp giữ nguyên tỷ lệ ảnh rồi thêm vùng đệm (padding) để đủ kích thước. Cách làm này giúp hạn chế biến dạng hình học của vùng tổn thương so với cách kéo dãn trực tiếp. Mask được xử lý để đưa về dạng nhị phân (nền = 0, tổn thương = 1) và giữ nguyên nhãn khi biến đổi kích thước. Ảnh đầu vào được chuẩn hóa về khoảng [0,1] để mô hình học ổn định hơn. Ngoài ra, nhóm áp dụng tăng cường dữ liệu như lật, xoay, thay đổi sáng tương phản, nhiễu và biến dạng nhẹ nhằm tăng đa dạng, giảm overfitting.

- Loại bỏ ảnh trùng trong tập kiểm tra (có lưu dự phòng)
- Chuẩn hóa 256×256 bằng giữ tỷ lệ + padding để tránh méo đối tượng
- Nhị phân hóa mask, chuẩn hóa ảnh và tăng cường dữ liệu

2.2. XÂY DỰNG MÔ HÌNH

2.2.1. Mô hình U-Net

2.2.1.1. Lý do chọn mô hình

Nhóm lựa chọn U-Net vì đây là kiến trúc đã được chứng minh hiệu quả cao trong các bài toán phân đoạn ảnh (đặc biệt là ảnh y khoa), nơi mục tiêu không chỉ nhận diện đối tượng mà còn cần xác định ranh giới chính xác theo từng pixel. U-Net có cấu trúc encoder–decoder giúp mô hình học được đặc trưng từ mức thấp đến mức cao: encoder trích xuất đặc trưng và nắm bắt ngữ cảnh tổng thể, trong khi decoder phục hồi kích thước để tạo ra mask phân đoạn. Điểm mạnh nhất của U-Net là skip connections, cho phép truyền trực tiếp thông tin không gian ở độ phân giải cao từ encoder sang decoder, nhờ đó giảm mất mát chi tiết khi downsampling và cải thiện đáng kể chất lượng biên của

vùng phân đoạn.

2.2.1.2. Quy trình xây dựng và huấn luyện mô hình

Trong đề tài này, nhóm xây dựng một quy trình đầy đủ cho bài toán phân đoạn vùng tổn thương trên ảnh da bằng mô hình U-Net. Quy trình được tổ chức theo các giai đoạn liên tiếp nhằm đảm bảo dữ liệu đầu vào đúng chuẩn, mô hình được huấn luyện ổn định và kết quả được đánh giá cả định lượng lẫn định tính. Trước khi huấn luyện, nhóm kiểm tra cấu trúc dữ liệu, sự tương ứng giữa ảnh và mask, đồng thời phát hiện ảnh trùng lặp giữa tập huấn luyện và tập kiểm tra để tránh sai lệch đánh giá. Tiếp theo, dữ liệu được chuẩn hóa về cùng kích thước (256×256) theo phương pháp giữ tỷ lệ và thêm viền đệm, giúp hạn chế biến dạng đối tượng. Mô hình U-Net được thiết kế với cấu trúc encoder–decoder và skip connection để giữ chi tiết biên. Quá trình huấn luyện theo dõi Loss và các chỉ số Dice/IoU,…cuối cùng lưu mô hình tốt nhất và dừng sớm khi không còn cải thiện.

Quy trình 6 bước: Khám phá → Tiền xử lý → Mô hình → Huấn luyện → Đánh giá → Dự đoán ảnh mới

Hình 2.4. Sơ đồ tóm tắt quy trình pipeline U-Net.

2.2.1.3. Cải tiến so với U-Net thông thường

Thêm Batch Normalization sau mỗi convolution: U-Net gốc thường chỉ dùng Conv + ReLU. Việc bổ sung BatchNorm giúp ổn định phân phối đặc trưng, giảm dao động gradient và cải thiện tốc độ hội tụ, đặc biệt khi dữ liệu đa dạng về ánh sáng/nhiễu.

Dùng padding=1 cho Conv 3×3 để "giữ kích thước": U-Net gốc thường làm co kích thước và phải crop khi nối skip connection. Trong mô hình của nhóm, padding giúp kích thước feature map được bảo toàn theo từng mức, giúp nối skip connection thuận lợi và giảm sai lệch biên do cropping.

Đầu ra 2 kênh tối ưu trực tiếp bằng CrossEntropyLoss: phù hợp chuẩn bài toán phân lớp pixel 2 lớp, ổn định và dễ huấn luyện.Tiền xử lý phù hợp dữ liệu thực tế: resize giữ tỷ lệ + padding về 256×256, giảm méo hình đối tượng so với resize kéo dãn.

Tăng cường dữ liệu mạnh (flip/rotate/shift-scale, brightness-contrast, noise, elastic): cải thiện khả năng tổng quát hóa.

Huấn luyện có kiểm soát: chống data leakage, lưu best theo Dice và dùng Early Stopping, giúp chọn mô hình tốt và tránh overfitting.

2.2.1.4. Kiến trúc mô hình

Mô hình gồm hai nhánh chính: encoder (co lại) và decoder (mở rộng). Ở encoder, ảnh đầu vào được trích xuất đặc trưng qua nhiều lớp tích chập, đồng thời giảm dần kích thước không gian để học các đặc trưng mức cao (từ chi tiết nhỏ đến ngữ cảnh tổng thể). Tại phần giữa (bottleneck), mô hình giữ biểu diễn trừu tượng nhất của ảnh. Ở decoder, mô hình tăng dần kích thước để khôi phục bản đồ phân đoạn về đúng kích thước ban đầu. Điểm nổi bật của U-Net là kết nối tắt (skip connections): đặc trưng từ encoder được nối trực tiếp sang decoder ở cùng mức, giúp giữ lại thông tin biên và cấu trúc chi tiết của tổn thương. Đầu ra là bản đồ phân lớp theo pixel với 2 lớp (nền và tổn thương), phù hợp với bài toán phân đoạn nhị phân.

- Encoder học đặc trưng đa mức và giảm kích thước.
- Decoder phục hồi kích thước và tạo mask phân đoạn.
- Skip connection giữ chi tiết biên, tăng chất lượng phân đoạn.

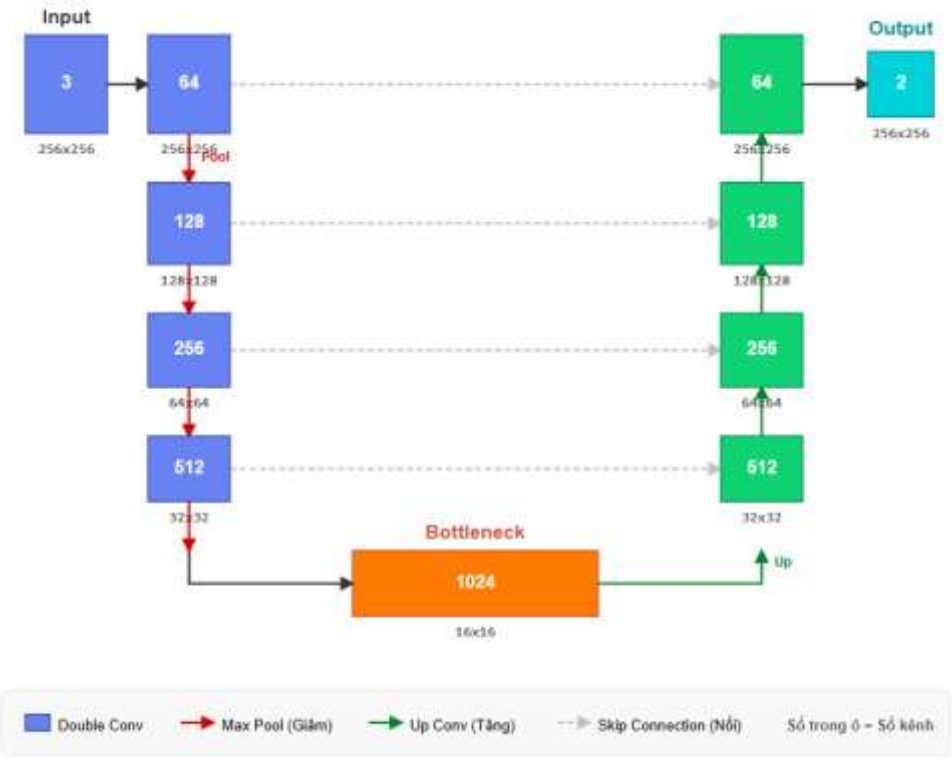

Hình 2.5. Kiến trúc mô hình U-Net.

a) Đầu vào (Input)

Đầu vào của mô hình U-Net là các ảnh nội soi có kích thước đã được chuẩn hóa về 256×256 pixels với 3 kênh màu RGB. Quá trình tiền xử lý dữ liệu bao gồm các bước sau: đầu tiên, ảnh gốc được đọc từ dataset dưới định dạng BGR và chuyển đổi sang

không gian màu RGB; tiếp theo, áp dụng kỹ thuật resize có đệm (adaptive resize with padding) để giữ nguyên tỷ lệ khung hình ban đầu của ảnh, tránh hiện tượng biến dạng khi thay đổi kích thước; cuối cùng, giá trị pixel được chuẩn hóa về khoảng [0, 1] bằng cách chia cho 255.0. Tensor đầu vào có shape (B, 3, 256, 256), trong đó B là batch size được thiết lập là 8. Các ảnh trong quá trình huấn luyện còn được tăng cường dữ liệu (data augmentation) thông qua các phép biến đổi như lật ngang, lật dọc, xoay, thay đổi độ sáng và độ tương phản để tăng tính đa dạng và khả năng tổng quát hóa của mô hình.

b) Khối DoubleConv

Mỗi khối cơ bản trong U-Net là DoubleConv, gồm hai lớp tích chập liên tiếp (kernel 3×3, padding=1), mỗi lớp đi kèm Batch Normalization và ReLU. Thiết kế này giúp trích xuất đặc trưng hiệu quả hơn và ổn định quá trình huấn luyện.

- Cấu trúc: (Conv 3×3 → BN → ReLU) lặp 2 lần
- Vai trò: tăng khả năng học đặc trưng và làm rõ biên vùng Polyp

c) Encoder (Downsampling)

Encoder gồm 4 mức. Ở mỗi mức, ảnh đi qua DoubleConv để tăng số kênh, sau đó qua MaxPooling 2×2 để giảm một nửa kích thước không gian. Đồng thời, các đặc trưng sau DoubleConv được lưu lại để dùng cho skip connections.

Bảng 2.2. Bảng mô tả 4 mức encoder.

Mức	**Kênh vào → Kênh ra**	**Kích thước fearture map**
down1	3 → 64	256×256
down2	64 → 128	128×128
down3	128 → 256	128×128
down4	256 → 512	32×32

Sau mỗi mức (trừ mức cuối trước bottleneck), MaxPooling 2×2 làm thay đổi kích thước theo chuỗi: 256×256 → 128×128 → 64×64 → 32×32 → (vào bottleneck sẽ xuống 16×16)

Điểm quan trọng: các feature map sau DoubleConv ở mỗi mức được lưu lại (c1, c2, c3, c4). Những đặc trưng này sẽ được dùng để nối tắt sang decoder ở giai đoạn tái tạo ảnh, giúp giữ lại thông tin biên/chi tiết.

- Encoder: giảm kích thước không gian, tăng số kênh đặc trưng.
- Lưu đặc trưng trung gian để phục vụ skip connections.

d) Bottleneck

Bottleneck là phần nằm ở đáy của kiến trúc U-Net, đóng vai trò cầu nối giữa nhánh Encoder và nhánh Decoder. Sau khi đặc trưng đã được trích xuất và giảm dần kích thước qua các bước downsampling, bottleneck là nơi mô hình đạt mức biểu diễn trừu tượng cao nhất: kích thước không gian nhỏ nhất (với đầu vào 256×256 thì feature map tại đây có kích thước 16×16) nhưng số kênh lớn nhất. Trong mô hình của nhóm, bottleneck sử

dụng một khối DoubleConv để chuyển số kênh từ 512 lên 1024, giúp tăng khả năng tổng hợp thông tin ngữ nghĩa quan trọng của toàn ảnh. Nhờ đó, mạng có thể nắm bắt được các đặc trưng mang tính tổng quát như hình dạng, vị trí tương đối và ngữ cảnh của vùng đối tượng so với nền. Các đặc trưng giàu ngữ nghĩa này sau đó được đưa vào Decoder để phục hồi kích thước và tái tạo bản đồ phân đoạn, đồng thời kết hợp với thông tin chi tiết từ các skip connections nhằm tăng độ chính xác của đường biên.

e) Decoder (Upsampling)

Decoder (Upsampling) và Skip Connections là nhánh "mở rộng" của U-Net, có nhiệm vụ phục hồi dần kích thước không gian của đặc trưng từ mức nhỏ nhất ở bottleneck trở về đúng kích thước ảnh đầu vào, từ đó tạo ra bản đồ phân đoạn theo từng pixel. Trong mô hình của nhóm, decoder gồm 4 bước upsampling liên tiếp. Ở mỗi bước, mạng sử dụng phép upsampling bằng tích chập chuyển vị để tăng gấp đôi kích thước feature map (ví dụ 16×16 → 32×32 → 64×64 → 128×128 → 256×256), đồng thời giảm dần số kênh theo hướng ngược lại với encoder. Sau khi upsample, đặc trưng ở decoder sẽ được nối với đặc trưng tương ứng từ encoder thông qua skip connections. Cơ chế này giúp kết hợp "ngữ nghĩa sâu" (từ bottleneck/decoder) với "chi tiết không gian" (từ encoder), nhờ đó mô hình không bị mất thông tin biên do quá trình pooling. Sau bước nối, mạng tiếp tục dùng các lớp tích chập để tinh chỉnh và hợp nhất đặc trưng, giúp dự đoán mask rõ ràng hơn, đặc biệt ở ranh giới và các vùng đối tượng nhỏ.

f) Đầu ra (Output layer)

Sau bước decoder cuối cùng, mô hình thu được feature map 64 kênh tại kích thước 256×256. Nhóm sử dụng một lớp tích chập 1×1 để ánh xạ từ 64 kênh về đúng số lớp phân đoạn: 64 → 2 kênh (n_classes = 2)

Đầu ra của mô hình là logits (chưa qua softmax) cho từng pixel ở 2 lớp. Trong quá trình huấn luyện, logits này được đưa vào hàm mất mát CrossEntropyLoss, vì CrossEntropyLoss yêu cầu đầu vào là logits và nhãn mask ở dạng chỉ số lớp (0 hoặc 1).

- Output logits: (B, 2, 256, 256)
- Mask nhãn: (B, 256, 256) với giá trị {0,1}

2.2.2. Mô hình FCN – Resnet34

2.2.2.1. Lý do chọn mô hình

Mô hình FCN–ResNet34 được lựa chọn vì phù hợp trực tiếp với bài toán phân đoạn ảnh theo từng pixel và đồng thời đảm bảo cân bằng tốt giữa hiệu quả và chi phí tính toán. FCN (Fully Convolutional Network) là kiến trúc chuyên dụng cho semantic segmentation do toàn bộ mạng chỉ gồm các lớp tích chập, cho phép tạo ra bản đồ dự đoán dày đặc tương ứng với từng điểm ảnh thay vì chỉ đưa ra nhãn cho toàn ảnh. Trong khi đó, ResNet34 đóng vai trò backbone trích xuất đặc trưng mạnh nhờ các kết nối tắt (residual connections), giúp việc lan truyền gradient ổn định hơn, tăng khả năng học được các đặc trưng quan trọng như biên, kết cấu và hình dạng của đối tượng. So với các

backbone sâu hơn (ResNet50/101), ResNet34 có số tham số và mức tiêu thụ tài nguyên vừa phải, phù hợp với điều kiện huấn luyện thực tế nhưng vẫn đủ mạnh để đạt chất lượng tốt. Ngoài ra, cấu trúc encoder–decoder của FCN kết hợp với cơ chế upsampling và các skip connections cho phép dung hòa thông tin ngữ nghĩa ở tầng sâu và chi tiết không gian ở tầng nông, từ đó cải thiện khả năng tái tạo biên và vùng đối tượng trong mask. Nhìn chung, FCN–ResNet34 là một lựa chọn baseline đáng tin cậy, dễ triển khai, dễ kiểm soát và có tiềm năng mở rộng bằng fine-tuning hoặc thay đổi chiến lược huấn luyện để tối ưu các chỉ số như Dice và IoU.

2.2.2.2. Quy trình xây dựng và huấn luyện mô hình

Quy trình pipeline FCN–ResNet34 được triển khai theo 6 bước liên tiếp.

1. Khám phá dữ liệu: Kiểm tra ảnh và mask có khớp nhau, tìm ảnh bị trùng lặp, phân tích kích thước ảnh và kiểm tra chất lượng mask.

2. Xử lý dữ liệu: loại bỏ ảnh trùng lặp, resize ảnh về 256×256 bằng padding để giữ tỷ lệ, chuẩn hóa giá trị mask về 0 và 1, thực hiện tăng cường dữ liệu (flip, rotate, noise, …) và chia dữ liệu theo tỷ lệ 70% train(70%) - 15% val (15%) - 15% test.

3. Xây dựng mô hình FCN–ResNet34: sử dụng ResNet34 làm nền (không pretrained), gồm encoder thu nhỏ ảnh qua 5 lớp, decoder phóng to ảnh bằng upsampling, kết hợp skip connections để nối encoder–decoder, và đầu ra là mask có kích thước tương ứng ảnh gốc.

4. Huấn luyện: dùng loss kết hợp CrossEntropy + Dice, tối ưu bằng AdamW, theo dõi các chỉ số như Dice, IoU, Accuracy; lưu mô hình tốt nhất và áp dụng dừng sớm nếu không cải thiện trong 10 epoch.

5. Đánh giá & trực quan: vẽ biểu đồ Loss/Dice/IoU, load mô hình tốt nhất, đánh giá trên tập Test và hiển thị kết quả dự đoán so với ground truth.

6. Dự đoán ảnh mới: xử lý ảnh mới giống bước training, dự đoán mask bằng mô hình và hiển thị kết quả.

Hình 2.6. Quy trình pipeline FCN – ResNet34

2.2.2.3. Cải tiến so với mô hình FCN - ResNet34 thông thường

Thay vì upsample bằng phép nội suy (bilinear) thuần, phần decoder sử dụng các lớp ConvTranspose2d kết hợp Conv – BatchNorm - ReLU. Cách này giúp quá trình phục hồi độ phân giải trở thành một bước "học được", thường cho mask mịn hơn và tái tạo cấu trúc tốt hơn.

Ngoài đặc trưng tầng sâu (ngữ nghĩa mạnh nhưng dễ mất chi tiết), mô hình kết hợp thêm đặc trưng từ các tầng trung gian (ví dụ layer3 và layer2). Việc trộn thông tin nhiều mức giúp cải thiện đường biên và giảm hiện tượng vùng dự đoán bị "bệt", đặc biệt với đối tượng nhỏ.

Trước khi nối các nhánh skip, các lớp 1×1 conv được dùng để giảm kênh (ví dụ 512 → 64, 256 → 64). Nhờ đó decoder nhẹ hơn, giảm tính toán và bộ nhớ nhưng vẫn giữ được lợi ích của việc kết hợp đặc trưng.

Hàm mất mát sử dụng dạng kết hợp CrossEntropy + DiceLoss, giúp tối ưu đồng thời phân loại theo pixel và chất lượng vùng đối tượng. DiceLoss đặc biệt hữu ích khi dữ liệu mất cân bằng giữa nền và vùng cần phân đoạn, từ đó hỗ trợ cải thiện Dice/IoU so với chỉ dùng CrossEntropy.

2.2.2.4. Kiến trúc mô hình FCN -ResNet34

Hình 2.7. Kiến trúc mô hình FCN – ResNet34

Kiến trúc mô hình FCN–ResNet34 được thiết kế theo dạng encoder–decoder với các thành phần chính bao gồm: đầu vào (input), encoder trích xuất đặc trưng dựa trên ResNet34, decoder phục hồi độ phân giải với cơ chế skip connection và đầu ra (output) tạo mask phân đoạn. Cơ chế skip connection giúp decoder kết hợp thông tin ngữ nghĩa từ tầng sâu và thông tin chi tiết không gian từ tầng nông, từ đó cải thiện chất lượng biên và độ chính xác của mask dự đoán. Cấu trúc được mô tả chi tiết qua các mục sau.

a) Đầu vào (Input)

Đầu vào của mô hình là ảnh RGB có kích thước 256 × 256 × 3, đã được tiền xử lý bằng phương pháp resize giữ tỷ lệ kết hợp padding. Ảnh được chuẩn hóa về khoảng [0, 1] bằng cách chia cho 255 và sắp xếp theo định dạng tensor (C×H×W) phù hợp với PyTorch.

b) Encoder (ResNet34)

Encoder sử dụng backbone ResNet34 gồm 5 khối chính (layer0 đến layer4), đóng vai trò trích xuất đặc trưng theo nhiều mức độ chi tiết.

- Layer 0–1: Bao gồm lớp convolution 7×7, batch normalization, ReLU, max pooling và khối residual đầu tiên. Đầu ra có 64 channels và kích thước giảm xuống còn 1/4 so với ảnh gốc (size /4).
- Layer 2: Khối residual thứ hai tăng số kênh lên 128 channels, kích thước giảm xuống size /8.
- Layer 3: Khối residual thứ ba tăng số kênh lên 256 channels, kích thước giảm xuống size /16.
- Layer 4: Khối residual cuối cùng tăng số kênh lên 512 channels, kích thước giảm xuống size /32. Đây là tầng có ngữ nghĩa cao nhất nhưng mất nhiều thông tin không gian.

Encoder thực hiện quá trình downsampling dần để nén thông tin và tăng khả năng trừu tượng hóa đối tượng.

c) Decoder (Upsampling)

Decoder có nhiệm vụ phục hồi độ phân giải không gian từ feature map tầng sâu và kết hợp thông tin từ các tầng nông thông qua skip connections.

- Reduce + Upsample từ Layer 4: Đặc trưng từ layer4 (512 channels) được giảm xuống 64 channels bằng lớp convolution 1×1 (reduce4). Sau đó, lớp ConvTranspose2d (kernel 4×4, stride 2) thực hiện upsampling gấp đôi kích thước, đưa feature map về size /16.
- Skip Connection với Layer 3: Đặc trưng từ layer3 (256 channels) được giảm xuống 64 channels (reduce3) rồi nối (concatenate) với đầu ra từ bước trước, tạo tensor 128 channels. Một khối convolution (dec4: Conv 3×3 + BN + ReLU) xử lý tensor này và giảm về 64 channels.
- Upsample và Skip Connection với Layer 2: Đầu ra 64 channels tiếp tục được upsample gấp đôi bằng ConvTranspose2d, đưa về size /8. Tensor này được nối

với đặc trưng từ layer2 (128 channels), tạo tensor 192 channels (64 + 128). Khối convolution (dec3: Conv 3×3 + BN + ReLU) xử lý và giảm về 64 channels.

- Final Upsample: Lớp ConvTranspose2d cuối cùng (kernel 16×16, stride 8) phóng to feature map từ size /8 trở về kích thước gốc (256×256) và đồng thời chuyển đổi từ 64 channels thành 2 channels tương ứng với 2 lớp phân đoạn (background và foreground).

Nếu kích thước đầu ra không khớp chính xác với đầu vào, một phép nội suy song tuyến (bilinear interpolation) được áp dụng để điều chỉnh.

d) Đầu ra (Output)

Đầu ra của mô hình là tensor kích thước 256×256×2, trong đó mỗi pixel có 2 giá trị logit tương ứng với xác suất thuộc lớp nền (0) hoặc lớp đối tượng (1). Trong quá trình inference, hàm argmax được áp dụng để chọn lớp có xác suất cao nhất, tạo thành mask nhị phân cuối cùng.

2.3. ĐÁNH GIÁ MÔ HÌNH

2.3.1. Mô hình U-Net

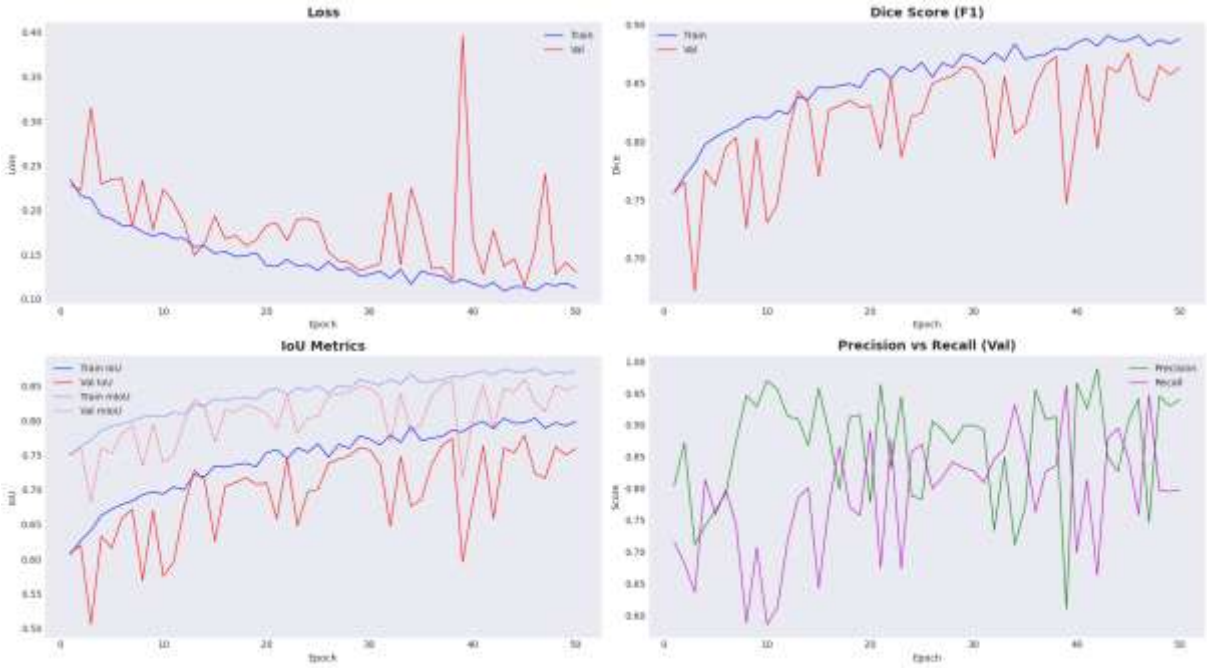

Hình 2.8. Biểu đồ trực quan lịch sử huấn luyện mô hình U - Net .

Loss trên tập train giảm đều và ổn định; loss validation nhìn chung giảm theo xu hướng nhưng dao động mạnh và có vài “spike”, cho thấy dữ liệu validation có những mẫu khó/khác biệt so với train. Dice và IoU trên train tăng dần, đường validation tăng theo nhưng biến động, chứng tỏ mô hình học được đặc trưng phân đoạn tốt và khả năng tổng quát hóa khá, tuy nhiên vẫn nhạy với một số ảnh khó.

Bảng 2.3. Bảng kết quả đánh giá mô hình trên tập Test mô hình U - Net

Chỉ số	**Kết quả**
Pixel Accuracy	0.9620
Mean IoU	0.8907
IoU (Object)	0.8280
Dice Score	0.9059
Precision	0.9153
Recall	0.8967

Mô hình đạt Pixel Accuracy = 0.9620, Dice = 0.9059, mIoU = 0.8907 và IoU (Object) = 0.8280, cho thấy khả năng phân đoạn nhìn chung tốt và mức độ chồng lấp giữa mask dự đoán với ground truth ở mức cao. Trong đó, Dice là chỉ số quan trọng nhất đối với bài toán phân đoạn vì phản ánh trực tiếp chất lượng vùng phân đoạn và vẫn phù hợp khi vùng đối tượng có kích thước nhỏ; kết quả Dice > 0.90 cho thấy mô hình tái tạo vùng đối tượng khá chính xác. IoU (Object) thấp hơn Dice như kỳ vọng do đây là thước đo "khắt khe" hơn, nhưng giá trị 0.8280 vẫn thể hiện mô hình nhận diện vùng đối tượng ổn định. Về xu hướng lỗi, Precision = 0.9153 cao hơn Recall = 0.8967 cho thấy mô hình có xu hướng dự đoán tương đối thận trọng (ít dự đoán dư), tuy nhiên đôi khi vẫn bỏ sót một phần vùng đối tượng ở các trường hợp biên mờ hoặc cấu trúc phức tạp. Cuối cùng, Pixel Accuracy chỉ nên dùng như chỉ số tham khảo vì có thể cao do nền chiếm tỷ lệ lớn, không phản ánh đầy đủ chất lượng phân đoạn đối tượng.

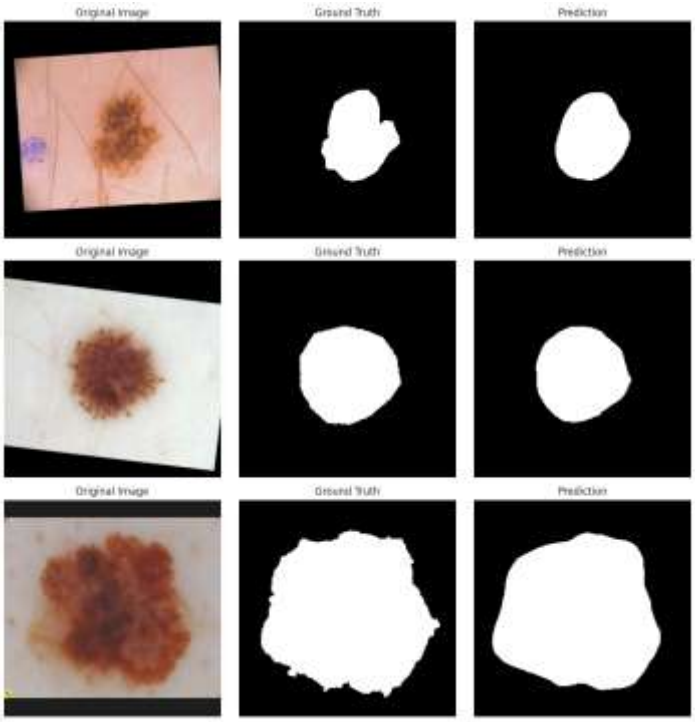

Hình 2.9. Hiện thị kết quả dự đoán trên tập Test mô hình U -Net

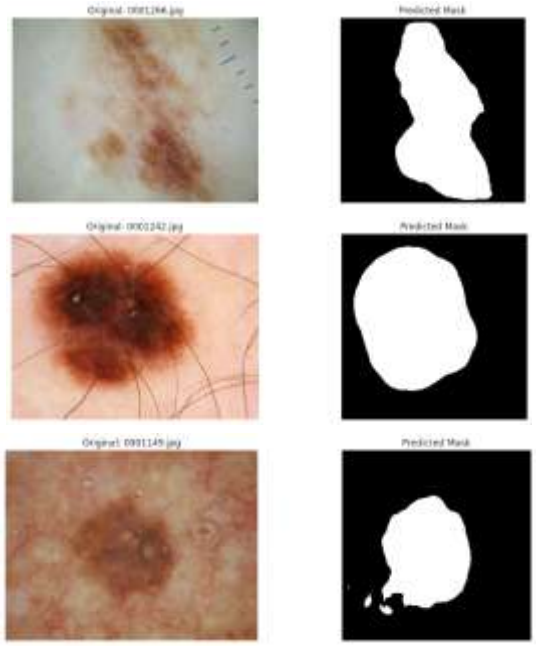

Hình 2.10. Hình ảnh dự đoán trên tập Test không Mask mô hình U - Net.

Mask dự đoán nhìn chung bám đúng vị trí và hình dạng tổng thể của vùng đối tượng; đường biên tương đối mượt và ổn định. Một số trường hợp có thể thấy hiện tượng làm tròn biên hoặc thiếu nhẹ ở rìa chi tiết nhỏ, phù hợp với kết quả Precision > Recall. Trên tập test không có mask, mô hình tạo mask hợp lý theo vùng màu/texture nổi bật, cho thấy khả năng áp dụng thực tế tương đối tốt.

2.3.2. Mô hình FCN – ResNet

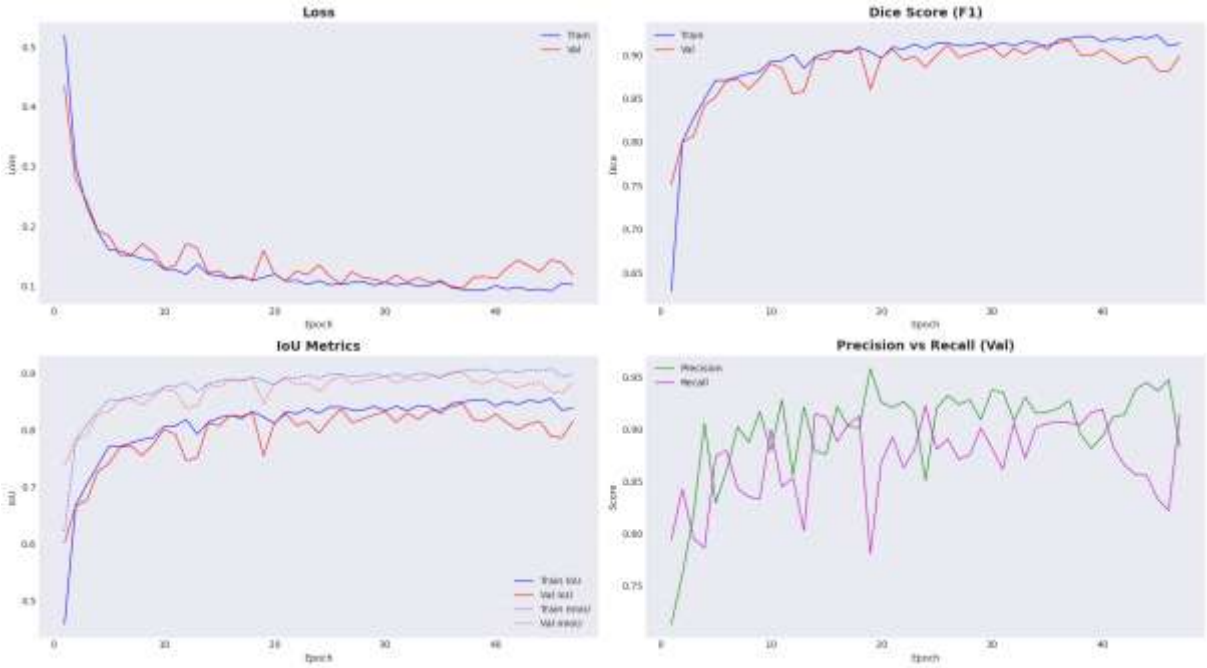

Hình 2.11. Biểu đồ trực quan lịch sử huấn luyện mô hình FCN – ResNet34 .

Loss giảm rất nhanh ở giai đoạn đầu và sau đó giảm chậm, ổn định về cuối cho thấy mô hình hội tụ tốt và quá trình học ổn định.

Dice Score (F1) của train và validation tăng mạnh trong các epoch đầu, sau đó đạt

ngưỡng cao và dao động nhẹ → mô hình học được cấu trúc vùng tổn thương khá hiệu quả. Ở giai đoạn cuối có dấu hiệu val Dice thấp hơn train Dice một chút, cho thấy overfitting nhẹ.

IoU và mIoU tăng đồng bộ với Dice, ổn định về cuối. Đường val thấp hơn train nhưng khoảng cách không lớn cho thấy khả năng tổng quát hóa khá tốt.

Precision và Recall (Val) duy trì mức cao nhưng dao động: precision thường nhỉnh hơn recall mô hình có xu hướng dự đoán "chắc" hơn, ít dương tính giả nhưng vẫn có thể bỏ sót một phần vùng đối tượng ở một số trường hợp.

Bảng 2.4. Bảng kết quả đánh giá mô hình trên tập Test mô hình FCN – ResNet34

Chỉ số	**Kết quả**
Pixel Accuracy	0.9683
Mean IoU	0.9081
IoU (Object)	0.8551
Dice Score	0.9219
Precision	0.9294
Recall	0.9145

Pixel Accuracy = 0.9683: rất cao, cho thấy phân loại theo pixel nhìn chung tốt (tuy nhiên chỉ số này thường "dễ cao" vì nền chiếm nhiều).

Dice = 0.9219: chất lượng phân đoạn vùng đối tượng rất tốt, phản ánh độ chồng khớp cao giữa mask dự đoán và ground truth.

IoU(Object) = 0.8551 và mIoU = 0.9081: IoU cho lớp đối tượng ở mức tốt; mIoU cao cho thấy mô hình phân biệt nền/đối tượng ổn định.

Precision = 0.9294, Recall = 0.9145: hai chỉ số cân bằng và đều cao; precision cao hơn recall xác nhận xu hướng ít "vẽ thừa" nhưng đôi lúc thiếu một phần đối tượng.

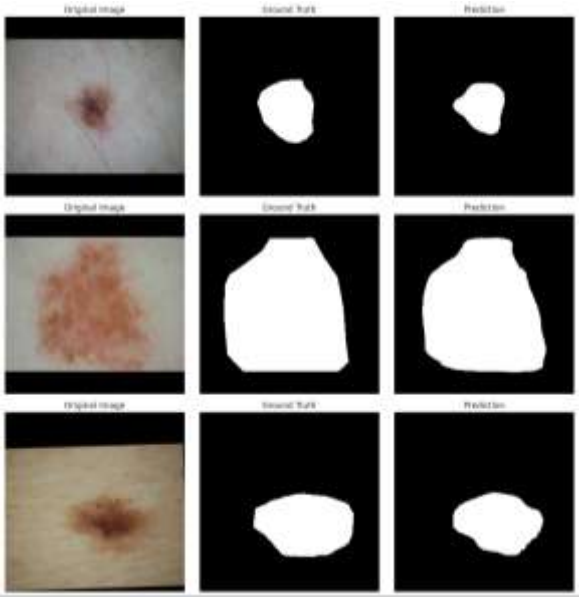

Hình 2.12. Hiện thị kết quả dự đoán trên tập Test mô hình FCN – ResNet34

Kết quả dự đoán cho thấy mô hình dự đoán đúng hình dạng tổng thể và vùng đối tượng được tách khá rõ. Sai lệch thường rơi vào các tình huống phổ biến của segmentation: biên chưa sát tuyệt đối, vùng đối tượng nhỏ, nhạt dễ bị thiếu, hoặc có thể xuất hiện lỗ nhỏ, nhấp nhô ở rìa mask.

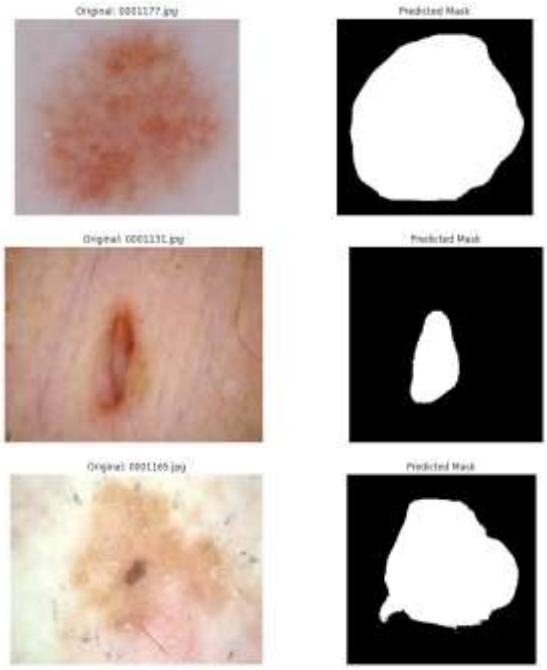

Hình 2.13. Hình ảnh dự đoán trên tập Test không Mask mô hình FCN – ResNet34.

Tổng quan mô hình dự đoán vùng đối tượng liên tục, hình dạng hợp lý, ít nhiễu rời rạc; hạn chế chủ yếu nằm ở độ sát biên (có thể hơi bao rộng hoặc hơi thiếu rìa tùy ảnh).

2.3.3. So sánh hai mô hình

Bảng 2.5. Bảng so sánh kết quả của hai mô hình

Chỉ số	U-Net	FCN-ResNet34
Dice Score	0.9059	0.9219
IoU (Object)	0.8280	0.8551
Mean IoU	0.8907	0.9081
Precision	0.9153	0.9294
Recall	0.8967	0.9145
Pixel Accuracy	0.9620	0.9683

FCN - ResNet34 cho kết quả tốt hơn U - Net trên tất cả các chỉ số, cho thấy khả năng phân đoạn và tổng quát hóa nhỉnh hơn trên bộ dữ liệu này.

Chất lượng phân đoạn tổng thể (Dice, IoU): Dice tăng từ 0.9059 lên 0.9219 (+ 0.0160) và IoU (Object) tăng từ 0.8280 lên 0.8551 (+ 0.0271). Điều này cho thấy mask dự đoán của FCN - ResNet34 chồng khớp với ground truth tốt hơn, đặc biệt ở vùng đối tượng (foreground).

Độ ổn định trên cả nền và đối tượng (Mean IoU): Mean IoU tăng từ 0.8907 lên 0.9081 (+ 0.0174), thể hiện FCN - ResNet34 phân biệt cả nền và đối tượng tốt hơn, ít

nhầm lẫn tổng thể hơn.

Hành vi dự đoán (Precision/Recall): Precision tăng từ 0.9153 lên 0.9294 cho thấy FCN - ResNet34 có xu hướng ít dự đoán nhầm vùng đối tượng hơn (giảm dương tính giả/FP). Recall tăng từ 0.8967 lên 0.9145 cho thấy mô hình cũng bỏ sót ít hơn giảm âm tính giả/FN). Việc cả precision và recall cùng tăng chứng tỏ cải thiện không chỉ do "dự đoán rộng hơn" hay "dự đoán chặt hơn", mà là cải thiện thực sự về chất lượng phân đoạn.

Pixel Accuracy: Pixel Accuracy tăng nhẹ từ 0.9620 lên 0.9683 (+ 0.0063). Chỉ số này thường bị ảnh hưởng bởi nền chiếm nhiều, nhưng vẫn cho thấy FCN-ResNet34 phân loại pixel chính xác hơn.

Kết luận: Trên bộ dữ liệu và thiết lập hiện tại, FCN - ResNet34 là mô hình tốt hơn U-Net, thể hiện rõ nhất ở các chỉ số quan trọng cho segmentation là Dice và IoU (Object), đồng thời cải thiện đồng thời Precision và Recall, nghĩa là vừa giảm vẽ thừa vừa giảm bỏ sót.

2.4. KẾT LUẬN CHƯƠNG

Trong chương này, nhóm đã trình bày chi tiết quy trình thực nghiệm từ khâu tiền xử lý dữ liệu, thiết lập tham số huấn luyện đến việc cài đặt hai mô hình U-Net và FCN-ResNet34. Kết quả đánh giá trên tập kiểm thử cho thấy cả hai mô hình đều hoạt động tốt, trong đó FCN-ResNet34 thể hiện sự vượt trội về các chỉ số độ chính xác (Dice Score, IoU,…) và khả năng tổng quát hóa.

Những số liệu thực nghiệm thu được ở chương này sẽ là cơ sở quan trọng để nhóm đưa ra những nhận xét, đánh giá tổng thể và đề xuất các hướng phát triển tiếp theo cho đề tài, nội dung này sẽ được trình bày chi tiết trong Chương 3.

CHƯƠNG 3: KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

3.1. KẾT LUẬN

Sau quá trình nghiên cứu lý thuyết và thực nghiệm trên bộ dữ liệu A0-2025 Medical Image Segmentation, đề tài đã hoàn thành các mục tiêu đặt ra, xây dựng được một pipeline phân đoạn ảnh y tế hoàn chỉnh và rút ra các kết luận chính như sau.

3.1.1. Về dữ liệu và đặc điểm bài toán

Nhóm đã làm việc với bộ dữ liệu ảnh soi da liễu thực tế gồm 1.279 ảnh, phản ánh đúng các thách thức thường gặp trong lĩnh vực phân đoạn ảnh y tế. Quá trình khảo sát dữ liệu cho thấy:

Kích thước ảnh và tỷ lệ khung hình không đồng nhất, nhiều ảnh có độ phân giải cao, dẫn đến khó khăn khi đưa về một chuẩn đầu vào thống nhất cho mô hình.

Vùng tổn thương có độ biến thiên rất lớn: có trường hợp rất nhỏ, khó nhận biết; có trường hợp chiếm phần lớn khung hình, làm thay đổi phân bố foreground/background.

Độ tương phản giữa vùng tổn thương và vùng da lành thay đổi theo từng ảnh, ảnh hưởng trực tiếp đến khả năng nhận diện biên.

Để khắc phục các vấn đề trên, nhóm đã triển khai các bước tiền xử lý phù hợp, bao gồm Resize with Padding (giữ tỷ lệ và giảm méo hình), chuẩn hóa dữ liệu và tăng cường dữ liệu (augmentation). Những bước này giúp cải thiện tính ổn định của dữ liệu đầu vào, tăng khả năng tổng quát hóa và giảm overfitting trong quá trình huấn luyện.

3.1.2. Về pipeline và quy trình thực nghiệm

Một quy trình huấn luyện đánh giá được xây dựng theo hướng chặt chẽ, gồm các bước: kiểm tra ảnh và mask, phát hiện và xử lý trùng lặp (giảm nguy cơ rò rỉ dữ liệu), thiết kế Dataset/DataLoader, huấn luyện theo epoch, theo dõi các chỉ số (Dice, IoU, mIoU, Precision, Recall, Pixel Accuracy), lưu mô hình tốt nhất theo validation và trực quan hóa kết quả dự đoán. Pipeline này giúp đảm bảo kết quả thực nghiệm có tính nhất quán, dễ tái lập và thuận lợi cho việc mở rộng, so sánh các mô hình khác.

3.1.3. Về mô hình và khả năng học đặc trưng

Nhóm đã cài đặt và huấn luyện thành công hai kiến trúc phổ biến cho phân đoạn ảnh y tế là U-Net và FCN–ResNet34:

U-Net với cấu trúc encoder–decoder đối xứng và các skip connections thể hiện ưu điểm trong việc phục hồi thông tin không gian và biên đối tượng, phù hợp với phân đoạn vùng tổn thương có hình dạng đa dạng.

FCN–ResNet34 sử dụng ResNet34 làm backbone giúp trích xuất đặc trưng mạnh nhờ cơ chế residual, hỗ trợ học sâu ổn định hơn. Kết hợp với cơ chế FCN tạo bản đồ dự đoán theo pixel, mô hình thể hiện khả năng nhận biết vùng tổn thương tốt và ổn định.

3.1.4. Về kết quả thực nghiệm và so sánh mô hình

Kết quả đánh giá trên tập kiểm thử cho thấy cả hai mô hình đều đạt hiệu năng cao.

Tuy nhiên, FCN–ResNet34 cho kết quả vượt trội hơn một cách nhất quán:

Dice Score = 0.9219 và Mean IoU = 0.9081, cao hơn U-Net (Dice = 0.9059, Mean IoU = 0.8907).

IoU (Object) = 0.8551 cho thấy khả năng phân đoạn lớp đối tượng tốt, giảm sai lệch vùng foreground.

Precision = 0.9294 và Recall = 0.9145 đều lớn hơn 0.91, thể hiện mô hình cân bằng tốt giữa hai yếu tố quan trọng: hạn chế dự đoán thừa (giảm dương tính giả) và giảm bỏ sót vùng tổn thương (giảm âm tính giả).

Pixel Accuracy = 0.9683 phản ánh độ chính xác pixel tổng thể cao, đồng thời củng cố kết luận mô hình hoạt động ổn định trên dữ liệu thực tế.

Từ các kết quả trên có thể khẳng định: mô hình FCN–ResNet34 là lựa chọn phù hợp và hiệu quả cho bài toán phân đoạn vùng tổn thương da liễu trên bộ dữ liệu A0-2025, đồng thời pipeline xây dựng có thể làm nền tảng cho các hướng cải tiến tiếp theo.

3.2. HẠN CHẾ

Mặc dù đạt kết quả khả quan, đề tài vẫn còn một số hạn chế cần được nhìn nhận để định hướng cải tiến:

Hạn chế do đặc tính dữ liệu và chất lượng ảnh:

Một số ảnh có độ tương phản thấp, vùng tổn thương mờ, ranh giới không rõ làm mô hình khó xác định đúng biên.

Nhiễu nền, thay đổi ánh sáng, màu da và kết cấu bề mặt cũng có thể khiến mô hình nhầm lẫn giữa vùng tổn thương và vùng da lành.

Hạn chế do chuẩn hóa kích thước đầu vào:

Việc đưa toàn bộ ảnh về kích thước cố định 256×256 (dù có padding để hạn chế méo) vẫn có thể gây mất chi tiết, đặc biệt với ảnh độ phân giải rất cao (ví dụ 4288×2848). Điều này ảnh hưởng đến khả năng phát hiện tổn thương nhỏ và làm biên dự đoán kém sắc nét hơn.

Hạn chế về phạm vi mô hình và chiến lược tối ưu:

Thực nghiệm mới dừng lại ở hai kiến trúc phổ biến, chưa mở rộng so sánh với các hướng hiện đại hơn như DeepLabv3+, FPN, hoặc nhóm mô hình Transformer/Attention cho segmentation.

Chưa đánh giá sâu theo từng nhóm trường hợp khó (tổn thương nhỏ, mờ, nhiễu nền mạnh) để phân tích lỗi có hệ thống và tối ưu theo từng nhóm.

3.3. HƯỚNG PHÁT TRIỂN

Để nâng cao chất lượng mô hình và tăng tính ứng dụng thực tế, có thể triển khai các hướng phát triển sau:

1. Cải tiến mô hình

Thử nghiệm các kiến trúc nâng cao như Attention U-Net, UNet++, DeepLabv3+,

FPN để cải thiện khả năng giữ biên và tận dụng ngữ cảnh đa tỉ lệ.

Nghiên cứu các mô hình kết hợp CNN–Transformer như TransUNet hoặc các biến thể ViT/SegFormer để tăng khả năng nắm bắt ngữ cảnh toàn cục và xử lý tốt ảnh phức tạp.

Tối ưu hàm mất mát theo hướng xử lý mất cân bằng foreground/background tốt hơn bằng các Hybrid Loss như Dice + Focal, hoặc Tversky/Focal Tversky để giảm bỏ sót tổn thương nhỏ.

2. Tối ưu hóa dữ liệu và chiến lược huấn luyện

Áp dụng Sliding Window / Tiling thay vì resize toàn ảnh đối với dữ liệu độ phân giải cao, giúp bảo toàn chi tiết và cải thiện phát hiện tổn thương nhỏ; sau đó ghép mask lại theo ảnh gốc.

Mở rộng dữ liệu huấn luyện (thu thập thêm hoặc sử dụng dữ liệu công khai tương tự), kết hợp các kỹ thuật tăng cường nâng cao hoặc domain adaptation để tăng khả năng tổng quát hóa.

Khai thác dữ liệu không nhãn bằng semi-supervised learning (pseudo-labeling, consistency regularization) nhằm tận dụng thêm nguồn dữ liệu thực tế.

3. Triển khai ứng dụng thực tiễn

Xây dựng ứng dụng web hoặc mobile tích hợp mô hình đã huấn luyện để người dùng tải ảnh lên và nhận mask dự đoán gần thời gian thực, hỗ trợ bác sĩ trong khâu sàng lọc và theo dõi tiến triển tổn thương.

Mở rộng hệ thống theo hướng “end-to-end” bằng cách tích hợp thêm bước phân loại bệnh học (classification) sau phân đoạn, nhằm không chỉ khoanh vùng tổn thương mà còn hỗ trợ dự đoán nhóm bệnh (lành tính/ác tính hoặc các loại tổn thương), tăng giá trị hỗ trợ lâm sàng.

TÀI LIỆU THAM KHẢO

[1] O. Ronneberger, P. Fischer, and T. Brox, "U-Net: Convolutional Networks for Biomedical Image Segmentation," in *Medical Image Computing and Computer-Assisted Intervention (MICCAI)*, 2015, pp. 234–241.

[2] J. Long, E. Shelhamer, and T. Darrell, "Fully Convolutional Networks for Semantic Segmentation," in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2015, pp. 3431–3440.

[3] K. He, X. Zhang, S. Ren, and J. Sun, "Deep Residual Learning for Image Recognition," in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016, pp. 770–778.

[4] T.-Y. Lin, P. Goyal, R. Girshick, K. He, and P. Dollár, "Focal Loss for Dense Object Detection," in *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, 2017, pp. 2980–2988.

[5] F. Milletari, N. Navab, and S. A. Ahmadi, "V-Net: Fully Convolutional Neural Networks for Volumetric Medical Image Segmentation," in *Fourth International Conference on 3D Vision (3DV)*, 2016, pp. 565–571.

[5] Kaggle, "A0-2025 Medical Image Segmentation Dataset," [Online]. Available: https://www.kaggle.com/competitions/a0-2025-medical-image-segmentation/data. [Accessed: Dec. 2025].